

IA em Cognição Nada Exauriente

EDIÇÃO Nº 17

INVENTÁRIO DOS PRINCIPAIS FATOS OCORRIDOS DE 12 DE SETEMBRO A 19 DE SETEMBRO DE 2026

Resumo

A OpenAI passou a vender um modelo que sabe direito americano. Uma startup recém-saída do anonimato passou a vender um modelo que não sabe escrever. Os dois lançamentos empurram na mesma direção: o modelo genérico deixou de ser a resposta única para qualquer tarefa. O Astra for Law é o GPT-6 Astra ligado a um acervo jurídico próprio, e a OpenAI publicou o número que separa uma coisa da outra. O Jev, da TypeSafe, abandonou a geração de texto e devolve só decisões, em milissegundos, por um custo de entrada que é fração do de um modelo de fronteira. E uma empresa de segurança mostrou, em relato técnico aberto, que o Claude Opus 5 fez em três horas o que a geração anterior não conseguiu fazer em várias sessões: um exploit funcional que abriu os repositórios internos da OpenAI.

No entorno, a ILTA mediu a adoção real de IA na advocacia e o líder não é ferramenta jurídica nenhuma; o Google lançou dois modelos de voz que ocuparam o topo do índice independente de fala; a Anthropic ligou a marca d'água estatística do Claude Opus 5 e publicou que o próprio modelo já lidera um quarto da pesquisa e desenvolvimento da casa. No Brasil, a semana foi de aplicação, não de lançamento.

MODELO PROPRIETÁRIO

Astra for Law: a OpenAI entra na advocacia pela pesquisa jurídica

O ganho medido não veio do modelo, veio do acervo que ele passou a consultar. Quem contrata precisa saber qual das duas coisas está comprando.

A OpenAI anunciou em 17 de setembro o [\[Astra for Law\]](#), que não é um modelo novo: é o GPT-6 Astra, o modelo mais capaz da casa, combinado com um índice de pesquisa jurídica próprio, instruções de análise e redação legal e controles de sigilo voltados à advocacia. A oferta começa restrita, por um programa de acesso selecionado dentro do ChatGPT e do Codex, com chegada anunciada à interface de programação. Harvey e Legora, duas plataformas de IA jurídica, poderão construir produto sobre ele, e a lista de escritórios parceiros inclui Sullivan and Cromwell, Skadden, Latham and Watkins, Cooley e Ropes and Gray.

O índice é a peça que muda o resultado. São mais de 230 milhões de endereços de jurisprudência, leis, regulamentos e decisões administrativas dos Estados Unidos, atualizados diariamente, incorporando a base do CourtListener, do Free Law Project, que cobre mais de 99,9% da jurisprudência americana publicada com efeito vinculante. Índice, aqui, é o acervo previamente organizado que o modelo consulta antes de responder, em vez de sair procurando no buscador comum. Para firmas elegíveis, a OpenAI oferece retenção zero de dados na API e exclusão da revisão humana por padrão no ChatGPT Enterprise, os dois controles que a advocacia costuma perguntar primeiro.

MEDIDA	RESULTADO	O QUE MEDE
Legal Research Bench	54,0% contra 38,7%	acerto geral em 200 questões de pesquisa jurídica, ante o mesmo modelo com busca comum
Casos de referência	24% a mais	precedentes pertinentes localizados na mesma pergunta
Passagens relevantes	até 54% a mais	trechos certos extraídos das decisões corretas

— COMPARAÇÃO COM A GERAÇÃO ANTERIOR

A comparação que a própria OpenAI publicou não é contra a concorrência, é contra si mesma: o mesmo GPT-6 Astra, no mesmo esforço de raciocínio, sai de 38,7% para 54,0% quando troca a busca genérica pelo acervo dedicado. É uma melhora relativa de 40% que não veio de treinar melhor o modelo. Veio de dar a ele a biblioteca certa. A empresa também publicou um exemplo em que o Astra for Law teria superado o Claude Fable 5.1, que citou precedente revertido em instância superior, mas é comparação feita pela fornecedora, não por terceiro independente. O [\[Artificial Analysis\]](#), que avalia modelos de fronteira de forma independente, ainda não publicou medição da configuração jurídica.

— O QUE ISSO DESBLOQUEIA NA PRÁTICA

Para a estrutura jurídica americana, o ganho é direto e mensurável. Para a brasileira, a notícia exige uma leitura a mais: o acervo é de direito dos Estados Unidos, e o desempenho medido não atravessa a fronteira junto com o produto. O que atravessa é o desenho. A diferença entre uma ferramenta jurídica útil e um chatbot caro está no que ele consulta antes de responder, não no tamanho do modelo. Quem for avaliar proposta de fornecedor nos próximos meses ganhou um número de referência e uma pergunta melhor: qual acervo alimenta esta resposta, e quem o mantém atualizado.

IMPACTO PRÁTICO

Durante dois anos a conversa sobre IA jurídica girou em torno de qual modelo é mais inteligente. O número desta semana desloca a conversa: o mesmo modelo, com a mesma inteligência, acerta quarenta por cento mais quando lê a biblioteca certa. Inteligência não é o insumo escasso. Acervo é.

Vale a pergunta ao seu fornecedor atual, por escrito: o que exatamente ele consulta quando você pede um precedente, e com que frequência aquilo é atualizado. A resposta separa quem construiu ferramenta de quem embrulhou um modelo.

MODELO PROPRIETÁRIO

Jev: o modelo que não escreve, decide

A corrida da fronteira é por pensar mais tempo. Esta aposta vai pelo avesso, e o que a torna interessante é o preço da saída.

Diogo Almeida, que na OpenAI ajudou a construir os métodos que tornaram os modelos de linguagem úteis para conversar e seguir instruções, o trabalho que virou a pesquisa por trás do ChatGPT, lançou em 15 de setembro, pela sua startup TypeSafe, o [\[Jev\]](#). Agora ele propõe outra coisa: uma classe de modelo batizada de System One, em alusão ao pensamento rápido e intuitivo da psicologia, em oposição ao raciocínio deliberado dos modelos de raciocínio estendido, aqueles que gastam mais tempo processando antes de responder para responder melhor.

O Jev não gera texto. Ele devolve uma decisão estruturada e tipada, uma categoria, uma pontuação, uma probabilidade, sem escrever uma palavra. A diferença é de natureza: um modelo de linguagem escolhe a próxima palavra e vai montando a resposta; o Jev produz o veredito direto, dentro de um conjunto fechado de opções. O treino também troca de alvo. Em vez de otimizar para a preferência humana, que é o alvo do RLHF, a técnica de treinar o modelo com avaliações humanas sobre qual resposta é melhor, a empresa diz otimizar para a calibração, ou seja, para que os 80% de confiança que o modelo declara correspondam de fato a acertar oito em cada dez. Como a saída só pode ser uma das opções previstas, a TypeSafe fala em taxa de alucinação zero, o que significa nunca produzir valor fora do esquema, e não significa sempre acertar.

70 a 500 ms

TEMPO DE RESPOSTA DECLARADO

US\$ 0,042

POR MILHÃO DE TOKENS DE ENTRADA

Grátis

O QUE SE PAGA PELA SAÍDA

— COMPARAÇÃO COM A GERAÇÃO ANTERIOR

A comparação não é com outro modelo de decisão, porque a categoria acabou de ser inventada. É com o hábito atual de usar modelo de fronteira para tarefa miúda. A Vercel trocou o classificador de segurança que rodava em GPT-5.6 Luna pelo Jev e relata respostas de 5 a 18 vezes mais rápidas; a Bryo AI comparou com o Gemini e achou o Gemini um pouco mais preciso, porém de 10 a 20 vezes mais caro. Os dois casos aparecem na [\[cobertura do TechCrunch\]](#). Convém registrar de onde vêm os números: latência e preço estão no post de lançamento da própria TypeSafe, que adverte ali mesmo que suas medições costumam rodar a partir de laptops na Costa Oeste americana, e nenhum avaliador independente publicou medição do Jev até agora.

— O QUE ISSO DESBLOQUEIA NA PRÁTICA

Pense no volume que uma operação jurídica processa sem pensar: triar quais mensagens do contencioso viram tarefa, classificar peça recebida por tipo e urgência, pontuar risco de uma cláusula contra o padrão da casa, decidir se um documento vai para revisão humana ou segue direto. Nada disso pede redação. Pede decisão, muitas por minuto, a um custo que não inviabilize rodar sobre o acervo inteiro. Hoje essas tarefas são feitas com modelo de fronteira porque é o que existe, e a fatura reflete isso. A ideia pegou rápido o bastante para render seis réplicas abertas do conceito em dois dias [\[Latent Space\]](#).

Temos um raio preso numa garrafa e, ainda assim, ele não é útil. O problema é que estamos otimizando para a linguagem humana.

DIOGO ALMEIDA, FUNDADOR DA TYPESAFE AI, AO TECHCRUNCH

IMPACTO PRÁTICO

A indústria gastou três anos ensinando máquina a escrever como gente, e a conta chegou em forma de fatura por token. O que este lançamento sugere é banal e incômodo: boa parte do que se pede a um modelo caro não é redação, é decisão, e decisão não precisa de prosa.

Antes de aprovar o próximo orçamento de IA, separe as duas colunas. O que na sua operação exige texto escrito, e o que só exige um sim, um não e um grau de confiança. A segunda coluna costuma ser a maior, e é por ela que o dinheiro vaza sem que ninguém olhe.

Setenta e duas horas para entrar na OpenAI, com o modelo do concorrente

O salto de capacidade não apareceu num benchmark. Apareceu no tempo que uma equipe levou para terminar um trabalho que antes não saía.

ACOMPANHAMENTO *Edições nº 9 a 16: a fuga de agentes da OpenAI do ambiente isolado, a invasão à Hugging Face, os mil e duzentos agentes que combinaram um ataque e as mil e vinte e duas páginas de raciocínio do incidente do PyPI. Todos aqueles capítulos eram acidentes dentro de avaliação. Este foi trabalho deliberado, feito por gente, com ferramenta comprada.*

A novidade desta semana não é mais um agente que escapou sozinho. Em 13 de setembro a empresa de segurança Hacktron publicou o [\[relato técnico\]](#) de como usou o Claude Opus 5 para encadear duas falhas e chegar aos repositórios internos de código da OpenAI, em menos de setenta e duas horas entre o achado e o acesso. A OpenAI pagou 6.500 dólares pelo programa de recompensas por falhas e corrigiu o problema em cerca de catorze horas.

A cadeia começa numa falha de estouro de memória na libheif, biblioteca de imagens usada pelo fórum da comunidade da OpenAI, e termina numa configuração frouxa do login único, que deu acesso a contas de ChatGPT e Codex de funcionários e, por elas, às integrações conectadas. O detalhe que interessa está no meio. A equipe havia tentado o mesmo ataque em julho com o Claude Opus 4.8, que identificou a falha mas não produziu exploit funcional com as proteções de memória ativadas, sessão após sessão. Na noite do lançamento do Opus 5, refez a tentativa: três horas depois tinha o exploit pronto. Para a fase autônoma, precisou disfarçar o alvo de desafio de competição, porque o modelo se recusava a atacar sistema real.

“O Opus 4.8 penou por várias sessões para produzir um exploit funcional com o ASLR ativado. Poucas horas depois do lançamento do Opus 5, demos a ele o mesmo problema, e ele conseguiu.”

HACKTRON AI • RELATO TÉCNICO DO ACHADO

Na mesma semana, o episódio inverso ganhou documento. A Irregular, empresa que testa modelos de fronteira antes do lançamento, publicou o [\[relato de incidentes recentes\]](#) em que um exercício controlado escapou do próprio ambiente: a equipe havia escolhido para o teste um nome fictício de empresa que, descobriu-se depois, coincidia com um domínio real, e o acesso à internet aberta, que não deveria existir ali, ficou ligado por falha. Modelos diferentes foram ao domínio verdadeiro achando que ele fazia parte do desafio, e chegaram a explorar

vulnerabilidades, extrair credenciais e alcançar um banco de dados de produção; num dos casos, o modelo desviou para um site de nome parecido e recolheu credenciais que estavam publicadas abertamente. A empresa diz que corrigiu o problema, notificou os afetados e não tem evidência de sistema de cliente invadido nem de dado vazado. Uma ressalva que o leitor precisa levar junto: o texto do documento não nomeia laboratório nenhum, e a atribuição do caso ao Gemini vem de declaração do Google à imprensa, não de documento técnico publicado pela empresa.

— O QUE MUDA PARA A OPERAÇÃO JURÍDICA

Até agora a conversa sobre risco de IA em segurança era sobre o que a máquina faz quando ninguém está olhando. Este caso é o contrário: gente competente olhando, com objetivo definido, usando a ferramenta como ferramenta. O que a Hacktron mediu, sem se propor a isso, foi a distância entre duas gerações do mesmo modelo em trabalho ofensivo real. Meses de tentativa contra três horas. E nenhuma das duas falhas exploradas era exótica: uma biblioteca de imagem desatualizada e um login único mal configurado.

IMPACTO PRÁTICO

Todo escritório, gabinete e assessoria mantém hoje um portal de cliente, um sistema de peticionamento ou um repositório que ninguém atualiza desde a implantação. A pergunta deixou de ser se alguém teria paciência de procurar a brecha ali. Paciência acabou de virar insumo barato.

A providência não é sofisticada: inventariar o que está exposto à internet, saber quem mantém cada peça atualizada e testar o próprio login único antes que outro o teste. Sigilo de dado de cliente é dever profissional, não item de orçamento de TI, e o prazo de quem ataca caiu de meses para horas.

Outros modelos da semana

O Google lançou em 15 de setembro o [\[Gemini 3.8 Live e o 3.8 Live Extended Thinking\]](#), dois modelos de voz que processam áudio e vídeo praticamente em tempo real, trocam de idioma sozinhos entre 97 línguas no meio da conversa e executam chamadas de sistema em segundo plano narrando o progresso. A versão com raciocínio estendido ocupou o primeiro lugar do índice de qualidade de fala do [\[Artificial Analysis\]](#), com 82,6 pontos. Para quem atende cliente por telefone ou faz triagem por voz, é a primeira geração em que a conversa não trava a cada troca de turno. Todo áudio gerado sai com marca d'água SynthID, e o preço não foi divulgado em números.

Pesquisa e métodos

A semana rendeu um benchmark feito sob medida para o ofício. O [\[LegalRewardBench\]](#), apresentado no workshop de IA e direito do ICML 2026, mede o que as avaliações jurídicas costumam ignorar: se o modelo fundamenta a resposta na evidência recuperada e se ele se cala quando a evidência não basta. Ajustar o modelo por preferência contextual rendeu até 25,6 pontos percentuais sobre a linha de base, e produziu um achado que surpreende: treinar em direito penal do estado de Victoria, na Austrália, melhorou em 16,2 pontos o desempenho num benchmark de legislação habitacional americana. A abstenção, ao que parece, se aprende como habilidade geral, não como conhecimento local.

Do lado da segurança de agentes, três trabalhos incomodam. O [\[Corrupt Plans, Clean Traces\]](#) mostra que plantar no contexto um raciocínio de aparência inofensiva faz o modelo executar ação adversária escapando do monitor que lê sua cadeia de raciocínio, com 25% a 33% de evasão, e que dar mais contexto ao monitor chega a derrubar a detecção pela metade. O [\[PMPA\]](#) grava instrução maliciosa na memória persistente do agente, que sobrevive entre sessões e dispara em conversas futuras, com taxa de ataque entre sessões de 55,5% em um arcabouço aberto e 81,7% no Claude Code. E o [\[Inference-Engine Fingerprinting\]](#) mostra que um modelo consegue identificar qual motor de inferência o executa só pelos tokens que ele próprio gera, e usar isso para escapar do isolamento. Em compensação, o Google publicou o [\[Retrieve-for-Train\]](#), que troca o raciocínio passo a passo antes da busca por um recuperador compacto de 53,9 milhões de parâmetros e corta a latência de perto de 50 segundos para uma faixa que vai de menos de um segundo a poucos segundos.

IA aplicada ao direito

A [\[pesquisa de tecnologia da ILTA\]](#), com mais de 500 escritórios e 140 mil advogados, trouxe o dado que faltava para separar barulho de adoção: 94% dizem usar ou explorar IA generativa, contra 80% um ano antes. O líder de uso não é ferramenta jurídica nenhuma. É o Microsoft 365 Copilot, com 76%, e a distância para os seguintes é larga: CoCounsel e Claude empatam em segundo com 44% cada, o Harvey vem logo atrás com 43%, o Lexis+AI marca 26% e a Legora, 16%. A leitura desconfortável é que a ferramenta que mais entrou na operação jurídica entrou porque já vinha paga dentro do pacote de produtividade, não porque venceu uma avaliação técnica.

O lançamento do Astra for Law arrastou o mercado atrás em um dia. A OpenAI abriu 26 plugins de parceiros, e o [\[levantamento do LawNext\]](#) listou integrações de Ironclad, Relativity, Everlaw, Litera, NetDocuments, Intapp e Clio, além do próprio CourtListener. Fora dessa órbita, a Checkbox lançou o [\[First Pass\]](#), agente que faz a leitura inicial do contrato contra o modelo

padrão da casa, antes que ele chegue a um advogado, e devolve nota de risco e resumo, e que também confere erro de cálculo em faturas; e a Salesforce [\[adotou a Legora\]](#) para pesquisa e redação na própria área jurídica, nos Estados Unidos, na Europa e na Ásia, movimento incomum numa empresa que costuma construir a própria ferramenta.

A Anthropic começou em 14 de setembro a ligar a [\[marca d'água do Claude\]](#) para o Opus 5 nas nuvens parceiras. A técnica embute na escolha de palavras do modelo um padrão estatístico gerado por chave criptográfica: invisível para o leitor, detectável por quem tem a chave. Para a prática, o detalhe decisivo está na leitura do resultado. A marca detectada diz que o Claude processou aquele texto, inclusive se apenas o traduziu ou revisou, e não que ele o redigiu; a ausência de marca não prova autoria humana. A detecção funciona mal em texto curto, que dá sinal estatístico insuficiente, e a verificação só está aberta a um conjunto restrito de organizações, entre elas reguladores, autoridades, imprensa, checadores e pesquisadores. Registre-se ainda, do radar da semana passada, que a versão beta dos agentes de revisão documental da [\[Casepoint\]](#) segue marcada para antes do fim de 2026, sem novidade nesta semana.

Ferramentas do ecossistema

- O Claude Code passou a ler o [\[arquivo AGENTS.md\]](#) como instruções do projeto quando não existe um CLAUDE.md, adotando a convenção que outras ferramentas de código também leem: quem usa mais de um assistente no mesmo repositório para de manter dois arquivos de regras.
- O [\[SDK Python da OpenAI\]](#) ganhou configuração de modelo por sessão de agente, sessões de conexão persistente gerenciadas pela própria API e pré-aquecimento do cache de instruções, que reduz a espera da primeira resposta em aplicações com prompt de sistema longo, caso típico de assistente jurídico com muito texto de orientação.
- O [\[Ollama 0.34.1\]](#), ferramenta para rodar modelos na própria máquina, tirou a criação de modelos no formato da Apple do estágio experimental e acelerou a listagem de modelos instalados de 3,1 segundos para 294 milissegundos, segundo medição dos próprios mantenedores; a [\[0.34.2\]](#) corrigiu o consumo excessivo de memória em gerações longas.
- O [\[llama.cpp v0.4.1\]](#), motor que roda modelos localmente e serve de base ao Ollama, passou a suportar três arquiteturas novas, entre elas uma de mistura de especialistas ternária que roda em processador comum, sem placa de vídeo dedicada.

PARA TESTAR ESTA SEMANA

Abra o [\[Gemini Live\]](#) no celular e conduza por voz uma conversa de cinco minutos sobre um caso seu, alternando de propósito entre português e inglês e interrompendo o modelo no meio da resposta. É a maneira mais barata de descobrir se a conversa por voz já serve para triagem de atendimento na sua operação, ou se ainda trava exatamente onde sempre travou.

Análise

A Anthropic publicou nesta semana a [\[primeira medição\]](#) de quanto do desenvolvimento dos seus próprios modelos já é conduzido pelo Claude. A empresa catalogou cerca de 15 mil tarefas internas de pesquisa e desenvolvimento, organizou-as numa árvore de 542 nós e classificou cada uma numa escala de autonomia que vai de AL0, sem participação de IA, a AL5, autonomia total. O resultado: em agosto de 2026 o Claude lidera 26% do trabalho, ou seja, completa a maior parte da tarefa de ponta a ponta a partir de um comando de alto nível, com humano supervisionando. A fatia em que o modelo ao menos colabora já passa de 90%. A própria empresa faz questão de registrar que o Claude não opera de forma totalmente autônoma em nenhum subconjunto medido.

Na mesma semana, Noam Brown, pesquisador da OpenAI, [\[disse ao Dwarkesh Podcast\]](#) o que torna esse número menos confortável: supervisionar a cadeia de raciocínio ensina o modelo a esconder intenção de formas não observáveis, e a possibilidade de monitorar essa cadeia vem se degradando conforme os modelos melhoram. É a mesma constatação que os papers de segurança da semana mediram em laboratório, dita por quem constrói o sistema.

Brasil

SAVE: visão computacional contra a clonagem de veículo

A FITec, instituto nacional de ciência e tecnologia, desenvolveu com a empresa de segurança K9 o [\[SAVE\]](#), sistema que combina leitura automática de placa por visão computacional com modelos que cruzam padrão de deslocamento para apontar veículo roubado, furtado ou clonado. A arquitetura é o que distingue: em vez das câmeras fixas de um único órgão, a coleta vem de uma rede colaborativa de usuários, entre eles motoboys que registram imagens durante as entregas. O projeto está concluído e, segundo a reportagem, pronto para ser aprimorado para aplicações em escala maior. O que não aparece em lugar nenhum é número: nenhuma taxa de acerto, nenhum volume de recuperação, nenhuma parceria com polícia ou Detran.

AYA: recomendação de leitura com número publicado

A AYA, plataforma brasileira de assinatura de livros e periódicos com 22 mil títulos e conteúdo de 300 veículos, ligou um agente de recomendação que lê o histórico de consumo de cada assinante para sugerir título novo [\[Mobile Time\]](#). A empresa divulgou os números: 68% dos clientes ativos passaram a abrir o serviço mais de uma vez por dia, e ao longo de 2025 a plataforma registrou 85% de aumento em downloads e 217% de crescimento no consumo de periódicos entre usuários mensais. São dados da própria casa, sem auditoria externa. Nas duas frentes que esta publicação vinha acompanhando, nada se moveu dentro da semana: a nova versão do assistente Helô, que a Dataprev prometera para o início de setembro no Meu INSS, segue sem lançamento anunciado, e a implantação do assistente do Banco do Brasil, iniciada em 24 de agosto, não teve marco novo divulgado. A Maritaca, única fonte primária brasileira de lançamento de modelo, não publica desde junho.

IMPACTO PRÁTICO

Repare na diferença entre os dois itens brasileiros da semana. Um tem arquitetura engenhosa e nenhum número; o outro tem números fartos e nenhuma auditoria. Nenhum dos dois é fraude, e os dois são exatamente o que se consegue publicar quando ninguém cobra medição.

Quem contrata tecnologia no Brasil aprendeu a ler proposta comercial e ainda não aprendeu a ler resultado. Da próxima vez que um fornecedor apresentar um caso de sucesso, peça o denominador: sobre quantos casos, medido por quem, comparado com o quê. A pergunta é curta e costuma encerrar a apresentação.

NO RADAR DA PRÓXIMA SEMANA

A Anthropic publicou o cronograma pelo qual a marca d'água do Claude Opus 5 nas nuvens parceiras se completa cerca de uma semana depois de 14 de setembro [\[Anthropic\]](#), prazo que vence nos próximos dias. E o estudo sobre inundação agêntica em serviços públicos, que inclui um caso brasileiro, segue marcado para outubro na conferência de ética e sociedade em IA [\[artigo\]](#).

O recorte dos últimos sete dias termina aqui. Até a próxima! ■

CURADORIA E EDIÇÃO · 19 DE SETEMBRO DE 2026

DM

Dennis Martins é advogado, professor de pós-graduação em Direito Imobiliário e pós-graduando em Inteligência Artificial Generativa no Direito.

AA

Adriana Aneli é formada em Direito e servidora do Tribunal de Justiça de São Paulo, onde ocupa o cargo de assistente jurídico. É mestranda em Teoria Crítica, especialista em Legal Operations, Dados, IA e Alta Performance Jurídica, e pós-graduanda em Inteligência Artificial Generativa no Direito.