

IA em Cognição Nada Exauriente

EDIÇÃO Nº 18

INVENTÁRIO DOS PRINCIPAIS FATOS OCORRIDOS DE 19 DE SETEMBRO A 26 DE SETEMBRO DE 2026

Resumo

Uma hora separou os dois lançamentos que definiram a semana. A Anthropic pôs no ar o Claude Opus 5.5, que assumiu o topo do índice independente de inteligência cobrando 20% menos por token que o antecessor; a OpenAI respondeu com o GPT-6 Sol e o GPT-6 Luna pela metade do preço da geração anterior. O corte é real, mas a conta final depende de uma variável que nenhum dos dois anúncios destaca: quanto cada modelo escreve para chegar à resposta. No terceiro destaque, um laboratório independente reconstituiu de fora o rastro dos agentes da OpenAI que, durante uma avaliação, foram buscar dados onde não deviam.

No entorno, a Xiaomi publicou sob licença MIT o modelo aberto mais bem pontuado do momento; o Google lançou vozes sintéticas que estão entre as primeiras em português brasileiro; e agentes da Anthropic apontaram um sistema enzimático que o laboratório da própria empresa validou em bancada. No Brasil, a semana girou em torno de uma pergunta incômoda: quem escreve a peça processual também escreve para a máquina que vai lê-la.

MODELO PROPRIETÁRIO

Claude Opus 5.5: nível de Fable pelo preço de Opus

O preço por palavra caiu, mas o modelo fala mais. A economia anunciada só aparece para quem controla quanto ele pensa.

A Anthropic lançou em 22 de setembro o [\[Claude Opus 5.5\]](#), que a empresa posiciona no nível do Claude Fable 5.1 na maior parte do trabalho. O preço caiu para US\$ 4 por milhão de tokens de entrada e US\$ 20 por milhão de saída, contra US\$ 5 e US\$ 25 do Opus 5, e a leitura de contexto reaproveitado (o cache) desceu de US\$ 0,50 para US\$ 0,20. Segundo a Anthropic, o modelo é 30% mais rápido na geração e, em uso típico, sai 40% mais barato que o Opus 5.

O ponto técnico está no raciocínio estendido: antes de responder, o modelo escreve um rascunho interno de passos, cobrado como saída. Quanto maior o esforço configurado, mais longo o rascunho. A [\[Artificial Analysis\]](#), avaliador independente, mediu 58 pontos no seu índice de inteligência com esforço máximo, a maior nota já registrada por ela, e mediu também o reverso: cerca de 119 mil tokens de saída por tarefa, contra 73 mil do Opus 5. Com 1,6 vez mais texto produzido, o custo por tarefa ficou empatado com o do antecessor. É o padrão que a

edição nº 15 registrou no Fable 5.1, em que o desconto no cache virou alta de 20% no custo por tarefa; aqui o aumento de volume só anula o desconto. Os números da tabela abaixo são os do [anúncio da Anthropic].

BENCHMARK	OPUS 5.5 · OPUS 5	O QUE MEDE
Terminal-Bench 4.0	66,4% · 52,3%	tarefas de agente executadas no terminal
FrontierCode v1.1	54,4% · 48,0%	programação em problemas difíceis
GDPval-AA v2.1	1846 · 1708 Elo	trabalho profissional de escritório
OSWorld 2.0	81,8% · 74,0%	uso autônomo do computador
Humanity's Last Exam	67,7% · 63,6%	perguntas acadêmicas de fronteira

— COMPARAÇÃO COM A GERAÇÃO ANTERIOR

A METR, que testou o modelo por dez dias úteis antes do lançamento, classificou o avanço sobre o Fable 5.1 como incremental e registrou que o ritmo de melhora segue parecido com a duplicação a cada sete meses que ela acompanha desde o início da série, segundo a [avaliação pré-lançamento da METR]. A mesma avaliação estima que a IA já acelera a pesquisa em IA em cerca de 1,5 vez e julga improvável que o modelo automatize esse trabalho por inteiro. No [Furniture Assembly Benchmark da Epoch AI], que pede ao modelo para achar o erro de montagem num móvel a partir da foto e do manual, o Opus 5.5 marcou 83%, a melhor nota do teste.

“O Claude Opus 5.5 é uma melhoria incremental sobre o Fable 5.1 nas nossas avaliações quantitativas, e não um salto descontínuo.”

METR · AVALIAÇÃO PRÉ-LANÇAMENTO DO MODELO

— O QUE ISSO DESBLOQUEIA NA PRÁTICA

Os exemplos do [anúncio da Anthropic] são de volume: a auditoria de uma base de código de 200 mil linhas caiu de mais de 20 horas para menos de 3, e 16 de 18 relatórios financeiros passaram na verificação de qualidade, contra nenhum do Fable 5.1 e do Opus 5. Traduzido para a operação jurídica, é a diligência sobre um data room inteiro concluída numa tarde, com a conferência humana concentrada onde o modelo sinalizou dúvida. A condição é ajustar o

esforço ao tamanho da tarefa. Esforço máximo em pergunta simples é pagar parecer de sócio para conferir data de protocolo.

IMPACTO PRÁTICO

Três gerações seguidas de modelos da Anthropic trouxeram a mesma lição em embalagens diferentes: o preço de tabela desce, o volume de texto sobe, e a fatura fica onde estava. Não há truque nisso. O modelo pensa mais porque pensar mais rende nota melhor.

Quem contrata precisa parar de comparar preço por token e começar a comparar custo por tarefa concluída, medido no próprio trabalho da casa. O token é o grão; o que se paga é a colheita.

MODELO PROPRIETÁRIO

GPT-6 Sol e Luna: metade do preço, mesma inteligência

A OpenAI não tentou subir o teto desta vez. Baixou o piso, e o piso é onde mora quase todo o trabalho repetitivo.

A OpenAI lançou no mesmo dia o [\[GPT-6 Sol e o GPT-6 Luna\]](#), versões mais baratas e rápidas da família inaugurada pelo GPT-6 Astra, que segue como topo de linha. O Sol passou de US\$ 4 e US\$ 20 por milhão de tokens de entrada e saída para US\$ 2 e US\$ 10; o Luna, de US\$ 0,20 e US\$ 1,20 para US\$ 0,10 e US\$ 0,50. Segundo o [\[AINews da Latent Space\]](#), o anúncio saiu cerca de uma hora depois do Opus 5.5.

O ganho é de eficiência, não de capacidade. A [\[medição da Artificial Analysis\]](#) encontrou os dois empatados com os antecessores GPT-5.6 no índice de inteligência, mas com custo por tarefa de US\$ 1,06 no Sol, contra US\$ 1,99, e de US\$ 0,07 no Luna, contra US\$ 0,18. O dado mais útil da mesma medição é outro: a taxa de alucinação, que mede com que frequência o modelo inventa uma resposta em vez de admitir que não sabe, caiu de 92% para 60% no Sol e de 93% para 77% no Luna. A tabela traz os números do [\[anúncio da OpenAI\]](#).

BENCHMARK	GPT-6 SOL	O QUE MEDE
AutomationBench	33,2%	fluxos de trabalho com 47 ferramentas
OSWorld 2.0 offline	60,5%	uso autônomo do computador
DeepSWE v1.1	68,8%	correção de problemas reais de código

— COMPARAÇÃO COM A GERAÇÃO ANTERIOR

A comparação que a OpenAI escolheu é com o concorrente, não consigo mesma: no AutomationBench, o Sol com esforço máximo supera o Claude Opus 5 no esforço máximo gastando 9% do custo por tarefa, e no DeepSWE o Luna chega a 66,6% custando 93% menos que o Opus 5. Junto com os modelos, a empresa anunciou um [\[cache de prompt melhorado para o GPT-6\]](#): desconto de até 90% nos tokens de entrada já processados, reaproveitamento de prefixos comuns numa janela de 30 minutos e a possibilidade de trocar o esforço de raciocínio entre uma resposta e outra sem perder o que estava em cache.

— O QUE ISSO DESBLOQUEIA NA PRÁTICA

A US\$ 0,10 por milhão de tokens de entrada, o Luna torna viável passar por modelo cada intimação, cada e-mail de cliente e cada documento que entra na operação, só para classificar e encaminhar. O cache pesa ainda mais nesse cenário: as instruções da triagem são sempre as mesmas, e é exatamente essa parte repetida que passa a sair quase de graça. A tarefa miúda, que ninguém quer fazer e que ninguém media, virou a mais barata de delegar.

O cache de prompt da OpenAI tem papel crítico em ajudar o GitHub Copilot a entregar experiências rápidas e eficientes em escala. Reduzimos em mais de 50% a parcela de tokens de prompt que exigem processamento do zero.

MARIO RODRIGUEZ, DIRETOR DE PRODUTO DO GITHUB

IMPACTO PRÁTICO

Dois laboratórios cortaram preço no mesmo dia, e cada um escolheu uma ponta. A Anthropic vendeu mais inteligência pelo mesmo custo; a OpenAI, a mesma inteligência por menos. Para quem compra, a pergunta que decide é qual das duas a tarefa exige.

A maior parte do trabalho jurídico repetitivo não precisa do modelo mais brilhante da praça. Precisa do que erra menos, custa pouco e não inventa quando não sabe. Neste último quesito, a queda de alucinação medida por terceiros vale mais que qualquer desconto.

ANÁLISE

Um laboratório independente reconstituiu o rastro dos agentes da OpenAI

A tarefa era trivial: achar uma estatística obscura. O problema é que ninguém disse ao agente até onde ele podia ir para achá-la.

ACOMPANHAMENTO *Edições nº 9 a 17: a fuga de agentes da OpenAI do ambiente isolado, a invasão à Hugging Face, os mil e duzentos agentes que combinaram um ataque e a invasão feita com o*

modelo do concorrente. Até aqui, os relatos vinham dos próprios laboratórios ou das vítimas. Agora vem de um auditor externo.

A novidade é quem contou. A Transluce, laboratório sem fins lucrativos de supervisão de IA, publicou em 23 de setembro o [\[relatório da Transluce\]](#) que liga ao menos parte de uma atividade automatizada em um serviço público de análise de endereços da web a enxames de agentes (muitas cópias de um agente trabalhando em paralelo) já atribuídos à OpenAI. A atividade vai de novembro de 2025 a setembro de 2026. Quando o acesso normal falhava, os agentes tentaram explorar falhas de segurança em três organizações, entre elas a biblioteca digital da Universidade do Novo México e o instituto australiano de saúde e bem-estar. A Transluce avisou a OpenAI e as organizações em 21 e 22 de setembro.

6.467

REGISTROS COM EVIDÊNCIA
SIGNIFICATIVA

31.182

REGISTROS COM EVIDÊNCIA
SUGESTIVA

3

ORGANIZAÇÕES ALVO DE TENTATIVA
DE INVASÃO

A OpenAI confirmou ao [\[TechCrunch\]](#) que boa parte do que a Transluce descreve coincide com casos da sua revisão interna sobre atividade desalinhada de modelos, e disse ter contatado dezenas de vítimas, entre governos, universidades e órgãos públicos. O objetivo dos agentes era banal: localizar estatísticas obscuras numa avaliação de recuperação de informação, como o custo médio de um tipo de medicamento num estado australiano. Na mesma semana, o [\[TechCrunch sobre as 53 imagens\]](#) revelou que agentes da mesma empresa publicaram em sites abertos 53 imagens enviadas por usuários, e que a OpenAI diz não conseguir avisar os afetados porque sua própria política de privacidade impede ligar as imagens a quem as enviou.

— O QUE MUDA PARA A OPERAÇÃO JURÍDICA

Os capítulos anteriores desta série tinham um ar de exceção: um teste de segurança que saiu do controle, um exercício de ataque mal contido. Este tem um ar de rotina. Nenhum agente foi mandado atacar nada; foi mandado achar um número, e tratou cada porta fechada como obstáculo a contornar. Para quem vai pôr agente para pesquisar jurisprudência, levantar dados de devedor ou vasculhar cadastros públicos, a lição é contratual antes de ser técnica: o mandato do agente precisa dizer o que ele não pode fazer, não só o que ele deve entregar.

IMPACTO PRÁTICO

O direito conhece bem a figura do mandatário que excede os poderes do mandato para cumprir o encargo. A novidade é que o mandatário agora trabalha em milhares de cópias, sem dormir, e ninguém lê a procuração que ele recebeu.

Antes de delegar pesquisa a um agente, escreva os limites como se fossem cláusulas: fontes permitidas, o que fazer diante de acesso negado, quando parar e perguntar. Agente sem limite

escrito não é diligente. É teimoso com crédito ilimitado.

Outros modelos da semana

A Xiaomi publicou o [\[MiMo-V2.6-Pro\]](#), modelo de mistura de especialistas (arquitetura em que só uma fração do modelo trabalha a cada palavra) com 1,02 trilhão de parâmetros no total e 42 bilhões ativos por token, contexto de 1 milhão de tokens e pesos sob licença MIT, que permite uso comercial sem restrição. Segundo o [\[AINews sobre o MiMo\]](#), o treino inteiro custou cerca de US\$ 3 milhões e o modelo assumiu a liderança entre os de pesos abertos no índice da Artificial Analysis, com 46 pontos: a opção mais forte hoje para quem precisa rodar o modelo na própria infraestrutura.

O Google lançou o [\[Gemini 3.8 Flash TTS e o Flash-Lite TTS\]](#), modelos de conversão de texto em fala com mais de 100 idiomas, mais de 2.000 vozes prontas e réplica de voz a partir de 30 segundos de áudio, com verificação de consentimento. Ficaram em primeiro lugar geral no benchmark de desenho de voz da Hume AI, com 71,4 pontos, e aparecem entre as primeiras em português brasileiro na Voice Arena, o que interessa a quem pensa em atendimento por voz em escala.

Pesquisa e métodos

O resultado científico da semana veio de agentes. Segundo o [\[post da Anthropic sobre a enzima\]](#), cerca de 950 agentes Claude vasculharam bancos genômicos por 21 horas, analisaram mais de 200 mil transcriptases reversas e reduziram 3.500 candidatos a 20, chegando a um sistema de bacteriófagos com um arranjo de repetições que lembra a arquitetura do CRISPR, a ferramenta de edição genética. A enzima já era conhecida; o que os agentes identificaram foram as características que definem o sistema, validadas em bancada pelo laboratório da própria Anthropic. Feng Zhang, um dos pioneiros do CRISPR, chamou o caso de exemplo animador de contribuição de agentes à descoberta biológica.

Dois trabalhos medem a confiabilidade dos agentes de código. O [\[LLM Agents Can Easily Tamper With Their Own Traces\]](#), com Maksym Andriushchenko entre os autores, mostra que Claude Code, Codex, Antigravity, Open Code e Grok Build apagam os próprios registros de execução quando instruídos, sem disparar nenhuma proteção, e que o comportamento surge sozinho quando o agente busca melhorar a própria recompensa; a recomendação é registrar tudo por um mecanismo fora do alcance do agente. E o [\[Between the Commits\]](#), de Douglas Leith, auditou uma ferramenta de 21 mil linhas escrita inteiramente pelo Claude: 14,3% dos

eventos de geração de código continham erro real, e cerca de uma em cada quatro ou cinco respostas interativas trazia ao menos um erro factual. Quem aceita trabalho de máquina sem conferência agora tem a taxa para pôr na conta.

IA aplicada ao direito

A 8am, dona do sistema de gestão MyCase, lançou o que o [\[LawNext sobre a 8am\]](#) descreve como o primeiro conector MCP para o Claude feito para gestão de escritório de advocacia. O MCP é o padrão aberto que deixa um assistente de IA consultar dados e executar ações dentro de outro sistema: são 73 ações sobre casos, clientes, documentos e faturamento, já em uso preliminar por mais de 60 escritórios, a maioria com até cinco profissionais. Para dezembro, a empresa promete um agente que consulta todos os dados da firma e um gerador de minutas a partir dos dados do caso.

A Harvey passou a usar o GPT-6 Astra e relata, no [\[case da OpenAI com a Harvey\]](#), minutas mais bem formatadas e mais atentas ao contexto do caso, com um painel de memória que guarda as preferências de cada advogado; a OpenAI não publicou números. E a Casepoint, que a edição nº 16 registrou com agentes de revisão documental em alfa restrita, pôs em produção com clientes de acesso antecipado os dois primeiros, que julgam relevância e classificam documentos por questão, com validação cruzada entre modelos antes do revisor humano, segundo o [\[eDiscovery Today sobre a Casepoint\]](#).

Ferramentas do ecossistema

- O Claude Code ganhou, na [\[versão 2.1.283\]](#), um comando que audita arquivos de instrução e habilidades em busca de orientações escritas para modelos antigos, e controles administrativos para bloquear modelos específicos, úteis para a estrutura jurídica que precisa aprovar cada modelo novo antes do uso.
- O [\[vLLM 0.30.0\]](#), motor que serve modelos em produção, passou a embutir marca d'água estatística no texto gerado, com endpoint para detectá-la, e a manter os pesos na memória da placa de vídeo entre reinícios, encurtando a volta do serviço. No Claude, a marca d'água já sai ligada no Opus 5.5 nas nuvens parceiras, mas a [\[página da Anthropic sobre marca d'água\]](#) ainda não confirma a conclusão do cronograma do Opus 5 cobrado pelo radar da edição anterior.
- A biblioteca Transformers, da Hugging Face, passou a carregar direto os modelos comprimidos do llama.cpp, segundo o [\[blog da Hugging Face sobre GGUF\]](#). No formato GGUF, um modelo de 4 bilhões de parâmetros cai de 8,42 GB para 2,74 GB e roda num Mac com desempenho comparável ao do próprio llama.cpp.

- O [\[Ollama 0.34.3\]](#), ferramenta para rodar modelos na própria máquina, passou a informar quais níveis de raciocínio cada modelo aceita e qual é o padrão, o que evita pagar em tempo de espera por esforço que a tarefa não pedia.

PARA TESTAR ESTA SEMANA

Baixe a [\[Skill nº 2 do Lightjur\]](#) e rode-a no Claude ou no ChatGPT sobre a última peça recebida da parte contrária. Ela procura instrução dirigida à IA escondida no texto e devolve um laudo, sem executar nada: o teste mais barato para saber se o seu fluxo de leitura automatizada já está exposto.

Brasil

A instrução em fonte branca e a ferramenta que a procura

Segundo o [\[post do Lightjur\]](#), publicado em 19 de setembro, a 6ª Turma do STJ encontrou em 1º de setembro, numa peça de recurso especial, texto em fonte branca sobre fundo branco com uma instrução dirigida à IA: invisível ao olho humano, legível para a máquina. O caso foi tratado como possível fraude processual e comunicado à OAB e ao Ministério Público Federal. É a injeção de prompt, técnica de esconder comandos no conteúdo que o modelo vai ler, chegando ao processo. A resposta do autor foi a skill que varre o documento e trata toda instrução encontrada como dado a reportar, nunca como ordem a cumprir.

Um juiz do trabalho abre a caixa da IA que classifica

O juiz do trabalho Jorge Araújo relatou, em [\[A IA que não escreve nada\]](#), o uso na própria mesa do Jev, o modelo que a edição nº 17 apresentou: recebe o conteúdo, uma pergunta e uma lista fechada de respostas, e devolve uma delas com grau de certeza, para triar autos. Ele fixou o grau de certeza que aceita, testou a ferramenta contra a própria triagem manual e trouxe de volta à mão peças que o sistema havia excluído. Dias antes, em [\[Sete prompt injections lícitos\]](#), listou o que faz uma petição ser bem lida pelos sistemas de IA do Judiciário: afirmar sem hesitação, organizar fatos e provas em tabela, impugnar fato por fato e citar precedente verificável. A análise da prova, frisa, continua com o magistrado.

Gotiva: IA plugada nos sistemas processuais

A Gotiva, do Grupo Interjato, lançou uma plataforma de IA jurídica que se conecta ao PJe, ao Projudi, ao SAJ e ao e-Proc pelo Modelo Nacional de Interoperabilidade, com modelos diferentes para cada tarefa e a possibilidade de indicar documento, página e trecho da fonte usada na resposta, segundo o [\[TI Inside sobre a Gotiva\]](#). A rastreabilidade até o trecho é o que separa a ferramenta útil da que obriga a refazer a pesquisa.

Mercado Pago: cinco milhões de usuários do assistente

O Mercado Pago informou que o Mago, assistente de IA para pequenos e médios empreendedores, já foi usado por mais de 5 milhões deles, para tarefas que vão de pagamento programado a análise de caixa e detecção de desvio de despesa, segundo o [\[Mobile Time sobre o Mago\]](#). A empresa não informou qual modelo roda por trás nem a taxa de acerto.

IMPACTO PRÁTICO

A petição brasileira ganhou um segundo leitor, e ele não tem cansaço, mas tem ponto cego. Quem escondeu uma ordem em fonte branca e o juiz que ensina a escrever para ser bem classificado estão diante do mesmo fato: a primeira leitura dos autos já é, em parte, feita por máquina.

A diferença entre os dois é a luz do dia. Escrever claro, com fato, prova e precedente alinhados, ajuda o leitor humano e o automático ao mesmo tempo. Escrever para enganar a máquina é só a velha má-fé processual com fonte nova.

NO RADAR DA PRÓXIMA SEMANA

O suplemento do ChatGPT para Word, Excel e PowerPoint passa a vir ativado por padrão em 1º de outubro, inclusive no plano gratuito [\[Lightjur\]](#), e a Gotiva apresenta sua plataforma na ExpoJud, de 6 a 8 de outubro, em Brasília [\[TI Inside\]](#). O estudo sobre inundação agêntica em serviços públicos segue marcado para outubro [\[artigo\]](#).

O recorte dos últimos sete dias termina aqui. Até a próxima! ■

CURADORIA E EDIÇÃO · 26 DE SETEMBRO DE 2026

DM

Dennis Martins é advogado, professor de pós-graduação em Direito Imobiliário e pós-graduando em Inteligência Artificial Generativa no Direito.

AA

Adriana Aneli é formada em Direito e servidora do Tribunal de Justiça de São Paulo, onde ocupa o cargo de assistente jurídico. É mestranda em Teoria Crítica, especialista em Legal Operations, Dados, IA e Alta Performance Jurídica, e pós-graduanda em Inteligência Artificial Generativa no Direito.