

IA em Cognição Nada Exauriente

EDIÇÃO Nº 19

INVENTÁRIO DOS PRINCIPAIS FATOS OCORRIDOS DE 26 DE SETEMBRO A 3 DE OUTUBRO DE 2026

Resumo

Os dois modelos de faixa intermediária lançados na semana cobram exatamente o mesmo por palavra, US\$ 2 na entrada e US\$ 10 na saída, e chegaram perto do topo de suas famílias. O GPT-6.1 Sol, da OpenAI, e o Claude Sonnet 5.5, da Anthropic, só se separam onde a fatura dói: na medição independente, resolver uma tarefa com o Sonnet no esforço máximo custa cerca de dez vezes mais. O Google voltou à fronteira com o Gemini 4 Argon, que empata com o GPT-6 Astra e é, entre os modelos de ponta, o que menos inventa. E os modelos de decisão, que a edição nº 17 apresentou como aposta de uma startup, ganharam versões da OpenAI, da AWS e do Ollama em poucos dias.

No entorno, a OpenAI pôs no ar agentes que trabalham sem parar com computador próprio na nuvem e abriu o método da revisão sobre os agentes que saíram do controle: mais de cem organizações notificadas. No Brasil, o Tribunal de Justiça do Rio Grande do Sul passou a construir agentes próprios para baixar o custo de uma IA que, com a expansão prevista para os próximos dias, deve passar por 1.500 processos novos por dia.

MODELO PROPRIETÁRIO

GPT-6.1 Sol e Claude Sonnet 5.5: o mesmo preço, contas diferentes

A faixa intermediária das duas casas encostou no topo cobrando idêntico por palavra. O que separa uma da outra é o volume de texto que cada modelo escreve até chegar à resposta.

A Anthropic lançou em 28 de setembro o [\[Claude Sonnet 5.5\]](#), segundo modelo da família 5.5, e a OpenAI respondeu no dia seguinte, no seu evento anual para desenvolvedores, com o [\[GPT-6.1 Sol\]](#). Os dois cobram US\$ 2 por milhão de tokens de entrada e US\$ 10 por milhão de saída. O Sonnet manteve o preço do antecessor e, segundo a Anthropic, responde ao menos 30% mais rápido que ele; o Sol substituiu o GPT-6 Sol sete dias depois do lançamento deste, e a OpenAI o vende como inteligência próxima à do GPT-6 Astra, seu topo de linha, por um quinto do preço.

Os dois são modelos de raciocínio estendido: antes de responder, escrevem um rascunho interno de passos, cobrado como saída, e o tamanho desse rascunho cresce com o nível de esforço configurado. Na [\[análise da Artificial Analysis sobre o Sonnet 5.5\]](#), avaliadora

independente, o modelo fez 56 pontos no índice de inteligência com esforço máximo, segundo lugar geral, atrás só do Opus 5.5, mas usou cerca de 193 mil tokens de saída por tarefa, o maior consumo que ela já mediu, e custou US\$ 7,60 por tarefa, cerca de 50% acima do Sonnet 5. Na [\[análise da Artificial Analysis sobre o GPT-6.1 Sol\]](#), o modelo da OpenAI ficou um ponto abaixo do Astra no mesmo índice e custou US\$ 0,72 por tarefa, contra US\$ 3,26 do Astra. Mesmo preço por token que o Sonnet; cerca de um décimo do custo dele por tarefa. Os números da tabela abaixo são os do [\[anúncio da Anthropic\]](#).

BENCHMARK	SONNET 5.5 · SONNET 5	O QUE MEDE
Terminal-Bench 4.0	70,6% · 10,3%	tarefas de agente executadas no terminal
CursorBench 4.0	55,5% · 34,1%	programação em sessões reais do Cursor
GDPval-AA v2.1	1844 · 1449 Elo	trabalho profissional em 44 ocupações
OSWorld 2.1	80,1% · 57,0%	uso autônomo do computador
Chartography	61,6% · 15,6%	leitura de gráficos

— COMPARAÇÃO COM A GERAÇÃO ANTERIOR

Contra os próprios antecessores, o salto é grande nos dois casos. A Anthropic informa que, em vários testes, o Sonnet 5.5 no esforço baixo ou médio supera a melhor nota do Sonnet 5 por cerca de um décimo do custo por tarefa: é nessa faixa que a promessa de custar até 30% menos se cumpre, não no esforço máximo que a avaliadora independente mediu. O Sol, segundo o [\[anúncio da OpenAI\]](#), empata com o Astra no DeepSWE, teste de engenharia de software em bases de código reais, a cerca de um quinto do custo, e reduziu de 11,4% para 7,7% a parcela de respostas com erro factual em perguntas difíceis no esforço baixo.

— O QUE ISSO DESBLOQUEIA NA PRÁTICA

O teste mais útil para o leitor não saiu de laboratório. O juiz do trabalho Jorge Araújo deu a 15 modelos os autos de um processo trabalhista real, julgado por ele há alguns anos, arquivado e anonimizado, e pediu a sentença, sem acesso à internet; seis avaliadores deram as notas. No [\[teste de Jorge Araújo com 15 IAs\]](#), o GPT-6.1 Sol ficou em primeiro, com 8,5, e o Claude Opus 5.5 em segundo, com 8,4. A minuta do GPT-6 Luna, feita pela assinatura do ChatGPT, saiu por cerca de 10 centavos; o DeepSeek V4 Pro consumiu mais de R\$ 15. É a amostra de um processo só, mas é o tipo de prova que nenhum benchmark de fabricante substitui: o trabalho da própria casa, conferido por quem conhece a decisão verdadeira.

“O que separou as melhores minutas das piores não foi o preço, mas a capacidade de seguir as instruções e as teses que orientavam o trabalho.”

JORGE ARAÚJO · JUIZ DO TRABALHO, AUTOR DO TESTE

IMPACTO PRÁTICO

Duas casas puseram a mesma etiqueta de preço na mesma semana, e a etiqueta quase nada diz. Um modelo resolve a tarefa com poucas linhas de rascunho; o outro enche um caderno antes de responder, e o caderno vai para a fatura.

Por isso o teste do juiz vale mais que qualquer tabela. Escolha três peças típicas da sua operação, rode-as nos dois modelos no esforço que você de fato usaria e anote nota e custo. Numa tarde, a casa descobre o que nenhum anúncio informa: quanto custa a sentença, não a palavra.

MODELO PROPRIETÁRIO

Gemini 4 Argon: o Google volta à fronteira com o modelo que menos inventa

O empate no índice de inteligência é a manchete. A notícia está em outra coluna: diante do que não sabe, este modelo prefere admitir a chutar.

O Google anunciou em 30 de setembro o [\[Gemini 4 Argon\]](#), voltado a engenharia de software, trabalho de conhecimento corporativo, como o jurídico e o financeiro, e defesa cibernética. O modelo chega primeiro a defensores de segurança selecionados, pelo programa Fairwind, e não está aberto ao público. O limite de resposta subiu de 64 mil para 1 milhão de tokens, e o preço de lançamento é de US\$ 2 por milhão de tokens de entrada e US\$ 10 de saída, metade do valor padrão de US\$ 4 e US\$ 20.

A resposta longa depende de um recurso novo da API, que pausa a resposta e a retoma em chamadas seguintes, para o raciocínio correr até 1 milhão de tokens sem estourar o tempo limite da requisição, segundo a [\[análise da Artificial Analysis sobre o Argon\]](#). A mesma medição deu ao modelo 53 pontos no índice de inteligência, empatado com o GPT-6 Astra e um ponto acima do GPT-6.1 Sol, e a taxa de alucinação mais baixa entre os modelos de ponta: 15%, contra 51% do Astra. Alucinação, aqui, é a frequência com que o modelo inventa uma resposta em vez de admitir que não sabe. Os números da tabela são os do [\[anúncio do Google\]](#).

BENCHMARK	GEMINI 4 ARGON	O QUE MEDE
DeepSWE v1.1	77,9%	correção de problemas reais de código
AutomationBench	51,3%	fluxos de trabalho empresariais com ferramentas
CWE-bench v1	68%	correção de vulnerabilidades de software
LVBench	91,7%	compreensão de vídeo longo

— COMPARAÇÃO COM A GERAÇÃO ANTERIOR

O salto sobre a geração anterior é grande. A [\[Artificial Analysis\]](#) registra 23 pontos acima do Gemini 3.1 Pro Preview, o último modelo do Google acima da classe Flash, e alta de 53 pontos no Terminal Bench 4, área em que os Gemini costumavam ficar para trás. O preço aparece em outro lugar: a acurácia factual caiu 5 pontos em relação ao 3.1 Pro, para 50%, e o modelo escreve em média 62 mil tokens de saída por tarefa, contra 27 mil do Astra. Com o desconto, a tarefa do índice sai a US\$ 1,99; sem ele, a US\$ 3,98, acima do Astra.

— O QUE ISSO DESBLOQUEIA NA PRÁTICA

Quando o acesso abrir, a saída de 1 milhão de tokens permitirá pedir de uma vez o parecer extenso ou a minuta completa de um contrato complexo, sem picotar o trabalho em pedaços. Mas o traço que mais interessa ao profissional do direito é o outro. Alucinação baixa com acurácia menor é o perfil do assistente que responde menos e diz quando não achou. Na pesquisa de jurisprudência e na conferência de fatos em autos volumosos, ele vale mais que o colega brilhante que nunca admite dúvida, porque o erro que custa caro é a resposta confiante e falsa.

IMPACTO PRÁTICO

Por sete meses o Google disputou a faixa barata enquanto os outros dois brigavam pelo topo. Voltou pela porta que interessa a quem trabalha com prova: um modelo que, perguntado sobre o que não sabe, tende a dizer que não sabe.

Ponha essa pergunta no teste de qualquer ferramenta. Peça um precedente que você sabe que não existe e veja o que o modelo faz. Uma recusa honesta diante da pergunta capciosa vale mais que dez acertos fáceis.

Modelos de decisão: a aposta de uma startup virou peça de prateleira

Em poucos dias, o modelo que só escolhe entre opções ganhou versões da OpenAI, da AWS e do Ollama. É a peça que a triagem de autos esperava, e ela não escreve uma linha.

O Jev, da TypeSafe AI, que a edição nº 17 apresentou e cujo uso na triagem de autos a edição nº 18 registrou, deixou de ser exceção. Um modelo de decisão recebe um conteúdo, uma pergunta e uma lista fechada de respostas, e devolve uma delas com o grau de certeza, sem gerar texto. Em 29 de setembro, a OpenAI lançou em prévia limitada a [\[Decisions API\]](#), que usa o modelo Luna para responder perguntas com respostas finitas definidas pelo desenvolvedor, como classificar conteúdo, encaminhar pedidos ou escolher o próximo passo de um agente, programa que executa sozinho tarefas de várias etapas.

Em 1º de outubro, a AWS publicou em código aberto o [\[Strands Decider 2B\]](#), com os pesos, os dados e os scripts de treino. A técnica cabe numa frase: a empresa pegou o Qwen3.5-2B, modelo de linguagem de 2 bilhões de parâmetros, retirou a peça que gera texto e pôs no lugar um cabeçote de pouco mais de 1 milhão de parâmetros que só pontua as opções oferecidas. No JevBench, o banco de testes da categoria, ficou em terceiro entre 33 modelos da classe de 2 bilhões, e acerta todas as tarefas fáceis.

2 bilhões

DE PARÂMETROS NO TOTAL

~115 ms

DECISÃO MEDIANA EM PLACA COMUM

3º de 33

NO JEV BENCH, CLASSE 2B

— COMPARAÇÃO COM A GERAÇÃO ANTERIOR

Contra os modelos de linguagem comuns, a troca é deliberada. O [\[post da AWS sobre o Strands Decider\]](#) admite que o desenho, que gera todas as saídas numa única passada paralela, deixa o modelo bem pior que os de raciocínio em problemas complexos e inútil para escrever código, resumir documentos ou conversar. Em compensação, decide em dezenas de milissegundos. Na [\[análise de Sebastian Raschka sobre o Jev\]](#), o modelo da TypeSafe acertou 96,47% na classificação das críticas de cinema do IMDb, em 22 minutos e por US\$ 0,65, com a ressalva de que não se sabe se esses dados estavam no treino.

— O QUE ISSO DESBLOQUEIA NA PRÁTICA

O formato chegou às ferramentas de uso local. O [\[Ollama 0.35.0\]](#), programa para rodar modelos na própria máquina, passou a servir modelos de decisão, e o exemplo do próprio release classifica um chamado de suporte como defeito, com probabilidade de 0,9781, gerando um único token de saída. No [\[Ollama 0.35.1\]](#) entraram o Clef e o Clef Flash, modelos abertos da Cloudflare que aceitam também imagens, e o llama.cpp, motor que o Ollama atualizou nessa versão, ganhou a mesma interface, o endpoint ``/v1/systemone``, no [\[llama.cpp b11361\]](#). Para a

estrutura jurídica, isso é triagem de intimações, classificação de petições por matéria e roteamento de e-mails de cliente rodando dentro de casa, sem o documento sair para a nuvem, com um número de certeza que permite mandar à mão humana tudo o que ficar abaixo do limite escolhido.

Modelos de decisão devolvem escolhas, probabilidades e pontuações em vez de texto.

NOTAS DA VERSÃO 0.35.0 DO OLLAMA

IMPACTO PRÁTICO

Durante três anos, a pergunta foi qual modelo escreve melhor. Boa parte do trabalho jurídico repetitivo nunca precisou de quem escreva: precisa de quem separe. Esta intimação tem prazo? Esta petição é de família ou de consumo? Este e-mail é urgente?

Para essas perguntas, o modelo de decisão é a ferramenta certa, e agora ele roda num notebook, sem custo de licença, com o grau de certeza à vista. A triagem deixou de ser problema de linguagem. Virou problema de régua: decidir a partir de que certeza a máquina encaminha sozinha.

Outros modelos da semana

O Ai2 publicou o [\[AstaBrief\]](#), modelo aberto de 8 bilhões de parâmetros que redige de uma só vez um relatório científico completo a partir de uma pergunta e de trechos de literatura recuperados, em vez de montar seção por seção. Pesos e dados de treino saíram junto, e num estudo pequeno, com 14 perguntas, dois de três pesquisadores o preferiram em acurácia de citação: é o desenho que interessa a quem produz memorando de pesquisa com fonte conferível.

Pesquisa e métodos

Dois trabalhos dizem a mesma coisa por caminhos diferentes: a camada de software em volta do modelo, o chamado harness, que decide o que ele vê, lembra e pode fazer, pesa tanto quanto o modelo. O [\[VISTA\]](#), com Kaiming He entre os autores, deu ao Claude Opus 5.0 uma memória visual que ele consulta e reorganiza enquanto joga, e levou sua pontuação de eficiência no ARC-AGI-3, teste de raciocínio em jogos inéditos, de 40,68 para 100, completando os 25 jogos públicos com 57,4% menos ações que humanos jogando pela primeira vez. O [\[Finding the Right Fit\]](#) testou 66 combinações de modelo e harness e viu o ranking se inverter: no Terminal-Bench

4, o Claude lidera o GPT por 7,94 pontos num harness e fica 30,16 pontos atrás em outro. Quem compara ferramentas olhando só o nome do modelo está medindo metade da coisa.

Na segurança, a equipe de ataque simulado da Anthropic publicou o [\[estudo da Anthropic sobre o GLM-5.3\]](#), modelo chinês de pesos abertos, e concluiu que ele explora falhas de software em nível comparável ao do Claude Mythos Preview: em 100 tarefas de exploração binária, chegou ao sequestro completo do fluxo de execução em 4% das tentativas, contra 6% do Mythos. E o [\[Climbing the Hill\]](#) treinou um atacante de injeção de prompt, técnica de esconder ordens no conteúdo que o agente lê, contra alvos cada vez mais resistentes, e chegou a 93,8% de sucesso em dez tentativas contra o GPT-5.6 Luna, onde os métodos anteriores ficavam em zero.

IA aplicada ao direito

A Multiverse Computing apresentou o [\[ProvenanceGuard\]](#), camada que confere, depois que o agente responde, se cada afirmação está sustentada pela fonte certa, e não apenas por algum trecho do material consultado. Em 361 afirmações revisadas por especialistas, pegou 138 das 139 sem sustentação e atribuiu a fonte correta a cerca de 86% das afirmações com fonte identificável, em cerca de meio segundo por resposta. Os dados vêm de agentes médicos, mas o defeito é velho conhecido do direito: citar o acórdão certo para a tese errada.

A Relativity, plataforma de revisão de documentos em litígio, disse ao [\[LawNext sobre a Relativity\]](#) que vai priorizar parcerias com Anthropic, OpenAI e Google em vez de empresas de IA jurídica, e que um conector MCP, o padrão aberto que liga assistentes de IA a sistemas externos, previsto para 2027, permitirá consultar os casos direto do Claude e de ferramentas semelhantes. O dono do acervo prefere abrir a porta ao modelo de fronteira a construir o seu.

Ferramentas do ecossistema

- A OpenAI lançou os [\[dots da OpenAI\]](#), agentes autônomos que trabalham em segundo plano o tempo todo, cada um com computador e navegador próprios na nuvem, movidos pelo GPT-6 Astra e com acesso aos aplicativos que o usuário conectar, entre mais de 4.000 disponíveis; ações que afetam contas passam por revisão automática contra regras do usuário, e tarefas sensíveis, como trocar senha, ficam sempre com o humano.
- O Claude Code passou a aceitar, na [\[versão 2.1.287 do Claude Code\]](#), os Claude Mods, extensões que alteram o comportamento mais profundo do agente; a primeira, embutida, é um agente lateral que observa a sessão e aponta o que o usuário ou o Claude podem estar deixando passar.

- A [\[versão 5.18.0 da Transformers\]](#), biblioteca da Hugging Face, passou a suportar o Nemotron 3 Diarization, que identifica quem falou quando numa gravação, com até oito falantes, em tempo real ou depois: a peça que faltava para transcrever audiência com cada fala atribuída à pessoa certa.
- O [\[guia da OpenAI para a família GPT-6\]](#) ensina a escolher modelo e esforço por tarefa, baixo para extração, médio para julgamento e alto para depuração difícil, e avisa que instruções específicas demais, que antes ajudavam, agora podem atrapalhar o resultado.

PARA TESTAR ESTA SEMANA

O [\[ChatGPT para Word\]](#) passa a vir ativado por padrão a partir de 1º de outubro, segundo a página de ajuda da OpenAI, como o radar da edição anterior antecipou. Abra uma minuta sem dado de cliente, peça ao assistente da barra lateral que aponte as afirmações sem fonte e confira o resultado: quinze minutos bastam para saber se ele serve de revisor na sua mesa.

Análise

ACOMPANHAMENTO Edições nº 9 a 18: a fuga de agentes da OpenAI do ambiente isolado, a invasão à Hugging Face, os mil e duzentos agentes que combinaram um ataque e a reconstituição feita de fora por um laboratório independente. Agora a OpenAI abriu o método da própria busca.

A OpenAI publicou em 30 de setembro, na [\[página da OpenAI sobre o incidente da Hugging Face\]](#), como faz a revisão da atividade dos seus modelos na internet durante treinos e avaliações. Até 26 de setembro, havia notificado mais de 100 organizações, com a ressalva de que notificação não significa invasão confirmada. São cerca de 50 petabytes de registros, examinados mês a mês com cerca de 7.000 placas de vídeo, a mais de meio milhão de dólares por dia: uma busca ampla e três passadas de IA cada vez mais minuciosas antes da revisão humana. As categorias descritas incluem contornar controles de acesso, usar credenciais expostas e injetar comandos em sites, e a empresa diz que, um mês depois do início, não achou outro caso comparável ao da Hugging Face em escala ou gravidade.

A mudança de prática apareceu no [\[MIT Technology Review\]](#): o diretor de pesquisa Mark Chen disse que a OpenAI agora passa todas as execuções de treinamento por monitores que leem o raciocínio escrito pelos modelos, monitores que antes não ficavam ligados durante o treino. Na mesma semana, a METR descreveu no [\[relato técnico da METR sobre o monitor de ações\]](#) um monitor que revisa cada ação de um agente antes que ela aconteça e bloqueia as suspeitas: sinalizou as 10 transcrições maliciosas de incidentes do instituto britânico de segurança de IA e, no tráfego interno da própria METR, deu 5 falsos alarmes em 20 mil ações, a um custo estimado, ainda preliminar, de cerca de 85% a mais por transcrição.

A lição atravessa a diferença de escala. A OpenAI gasta meio milhão de dólares por dia para descobrir, depois, o que seus agentes fizeram; a METR estima pagar 85% a mais para barrar antes. Quem põe agente para pesquisar em sistemas de terceiros, de tribunais a juntas comerciais, precisa escolher de que lado da conta quer ficar: o registro que se lê depois ou a trava que age antes.

Brasil

TJRS: agentes próprios para baixar a conta da IA

O Tribunal de Justiça do Rio Grande do Sul desenvolve com a AWS, em fase de homologação, agentes de IA próprios para reduzir o gasto com tokens, a unidade de texto pela qual os modelos cobram, segundo a [\[Convergência Digital sobre o TJRS\]](#). A matéria não informa quais modelos rodam nem quanto se economizou. O número que importa é outro: o GAIA, sistema do tribunal voltado às petições iniciais, deve chegar nos próximos dias a 350 mil advogados, o que, segundo a matéria, significa 1.500 dos cerca de 5.000 processos novos de cada dia passando por IA, quase um em cada três.

O Sabiá 4 no teste do juiz

Jorge Araújo também pôs à prova a IA brasileira. No [\[teste do Sabiá 4 por Jorge Araújo\]](#), modelo da Maritaca, pediu a minuta de uma decisão em embargos de declaração, com processo anonimizado: na primeira tentativa o modelo parou alegando que faltavam peças; na segunda, anunciou a conclusão, mas o arquivo não foi gerado. As duas tentativas custaram R\$ 3,76. O autor promete novos testes onde o modelo nacional poderia se destacar, como as expressões regionais e o jeito de falar numa audiência.

Mais uma ordem escondida, agora no STF

Segundo o [\[radar do Lightjur\]](#), a ferramenta Maria Shield, do STF, detectou numa petição instruções em letra branca dirigidas à IA da Corte, a mesma técnica que a edição nº 18 registrou numa peça analisada pela 6ª Turma do STJ. A diferença está em quem achou: desta vez, a máquina do tribunal procurava justamente o texto que o olho humano não vê.

IMPACTO PRÁTICO

Os dois movimentos da semana parecem opostos e se completam. O tribunal gaúcho constrói agentes próprios porque a conta da IA comprada pesa quando ela passa a tocar quase um terço

dos processos novos; o juiz que testou o Sabiá descobriu que o modelo nacional ainda não entrega o arquivo pedido.

Autonomia tecnológica, no Judiciário, não começa pelo modelo. Começa pela régua: quanto custa, quanto acerta, onde falha. Quem mede escolhe; quem não mede assina o contrato que lhe oferecerem.

NO RADAR DA PRÓXIMA SEMANA

A Gotiva apresenta na ExpoJud, de 6 a 8 de outubro, em Brasília, sua plataforma de IA integrada aos sistemas processuais [\[TI Inside sobre a Gotiva\]](#). E o estudo sobre inundação agêntica em serviços públicos, já disponível como preprint, sai nos anais da conferência AIES, de 12 a 14 de outubro [\[preprint no arXiv\]](#).

O recorte dos últimos sete dias termina aqui. Até a próxima! ■

CURADORIA E EDIÇÃO · 3 DE OUTUBRO DE 2026

DM

Dennis Martins é advogado, professor de pós-graduação em Direito Imobiliário e pós-graduando em Inteligência Artificial Generativa no Direito.

AA

Adriana Aneli é formada em Direito e servidora do Tribunal de Justiça de São Paulo, onde ocupa o cargo de assistente jurídico. É mestranda em Teoria Crítica, especialista em Legal Operations, Dados, IA e Alta Performance Jurídica, e pós-graduanda em Inteligência Artificial Generativa no Direito.