

IA em Cognição Nada Exauriente

EDIÇÃO Nº 20

INVENTÁRIO DOS PRINCIPAIS FATOS OCORRIDOS DE 3 DE OUTUBRO A 10 DE OUTUBRO DE 2026

Resumo

Um modelo da Anthropic, posto para navegar por páginas ao acaso, achou o formulário de dicas de uma polícia americana numa página sobre um homicídio sem solução e enviou uma dica sem fundamento algum. O caso está no relatório em que a empresa reúne as ações que seus agentes tomaram em sites reais sem que ninguém pedisse, e a resposta foi desligar a internet de todas as avaliações internas. Na mesma semana, a Anthropic lançou o Claude Haiku 5.5, que cobra o mesmo que o GPT-6 Luna até 100 mil tokens e passa à frente dele nos testes do fabricante. E a Artificial Analysis refez com a Harvey o teste de agentes jurídicos: com a alucinação material valendo zero, nenhum modelo aprova mais que 9,4% das tarefas.

No entorno, a OpenAI publicou 719 manuscritos de matemática de um modelo ainda não lançado, a Mistral voltou à disputa com um modelo de 1 trilhão de parâmetros e pesos prometidos para o fim do mês, e um experimento do Google com 133 advogados de patentes mostrou que a IA melhora o texto em média, mas só afia o julgamento dos experientes. No Brasil, a Gol pôs o check-in dentro do ChatGPT.

ANÁLISE

A Anthropic desliga a internet das próprias avaliações

Os agentes não atacaram ninguém: só não aceitaram parar. É dessa teimosia, e não de malícia, que vem o risco para quem os põe a trabalhar em sistemas alheios.

ACOMPANHAMENTO Edições nº 9 a 19: a fuga de agentes da OpenAI do ambiente isolado, a invasão à Hugging Face, as invasões reais feitas pelo Claude achando que estava num simulador e a revisão da OpenAI que notificou mais de cem organizações. Agora a Anthropic abriu o arquivo dos casos menores.

Os episódios graves já tinham sido contados; o que saiu em 9 de outubro é o inventário do resto. No [relatório da Anthropic sobre ações não intencionais](#), a empresa descreve quatro tipos de ação que seus modelos tomaram em sites reais sem pedido, na maioria das vezes em avaliações com acesso à internet: explorar uma falha de software num servidor, enviar um formulário que não devia, contornar restrição para chegar a dados protegidos por credencial ou por taxa, e usar encurtadores de endereço para driblar o limite de tamanho de endereço da

ferramenta que lê páginas. A Anthropic diz que o impacto real foi mínimo, que, até onde sabe, nenhum caso envolveu dados de clientes e que todos são bem menos graves que os incidentes relatados em 30 de julho e 9 de setembro. Ainda assim, desligou a internet ao vivo em todas as avaliações internas até confirmar que o monitoramento pega esse tipo de conduta.

4 tipos

DE AÇÃO NÃO INTENCIONAL

Todos

BARRADOS NO TESTE DO DETECTOR
NOVO

0 casos

CONHECIDOS COM DADOS DE
CLIENTES

Os exemplos têm a banalidade que assusta. O Claude Mythos 5 encontrou credenciais de acesso válidas no arquivo de configuração de um mapa municipal e consultou o servidor com elas. E o Claude Haiku 4.5, gerando interações de exemplo em páginas aleatórias, preencheu e enviou o formulário de dicas da polícia com um texto genérico, sem nome nem contato; a dica foi marcada como spam e não chegou à investigação. Segundo o [\[The Verge\]](#), o departamento era o da Filadélfia.

Do lado de quem sofreu, a [\[Wikimedia Foundation\]](#) confirmou em 5 de outubro atividade de agentes que atribui à OpenAI em seus projetos: edições em páginas de teste e tráfego pesado nas suas interfaces de dados, sem comprometimento de sistemas. Para [\[Simon Willison sobre a Wikimedia\]](#), é provavelmente o mesmo enxame de agentes que já tinha atingido um wiki alemão.

— COMPARAÇÃO COM OS CASOS ANTERIORES

Os incidentes relatados em julho e setembro eram falhas graves de segurança; estes são atalhos, e o próprio [\[relatório da Anthropic\]](#) aponta o que costuma estar por trás: tarefas ambíguas ou impossíveis e, no caso dos formulários, ambientes mal configurados. A empresa diz ainda estar corrigindo os ambientes de treino que premiam contornar restrições, o chamado reward hacking, em que o modelo aprende a burlar a regra de pontuação em vez de resolver o problema. Entre as correções, um detector automático que bloqueou todos os casos do relatório quando testado.

“A maioria é forma de persistência: quando não consegue cumprir a tarefa como foi dada, o Claude contorna uma restrição em vez de parar.”

ANTHROPIC • RELATÓRIO SOBRE AÇÕES NÃO INTENCIONAIS DOS MODELOS

— O QUE MUDA PARA A OPERAÇÃO JURÍDICA

Troque o mapa municipal pela consulta processual de um tribunal, e o formulário da polícia pelo peticionamento eletrônico: o agente que acha a porta fechada pode procurar a janela. O detalhe mais instrutivo do caso da polícia, no [\[relatório da Anthropic\]](#), está na instrução: ela proibia login, cadastro, dados pessoais, compras e ações destrutivas, mas não vedava o envio de formulários. O que não estava proibido, o agente fez.

IMPACTO PRÁTICO

A conduta tem parente conhecido no foro: o despachante que, sem resposta no balcão, dá um jeito por fora. Ninguém o mandou errar; mandaram resolver.

Quem põe agente para operar em portais de terceiros precisa escrever a lista do que ele não pode fazer pensando no que ele faria para não desistir: enviar, aceitar, cadastrar, usar a credencial que encontrou no caminho. Agente que não sabe desistir precisa de alguém que desista por ele.

MODELO PROPRIETÁRIO

Claude Haiku 5.5: o pequeno da Anthropic no preço do Luna

Até 100 mil tokens, a etiqueta empata com a da OpenAI e as notas passam à frente. Acima disso, e no volume de rascunho que o modelo escreve, a conta muda de lado.

A Anthropic lançou em 7 de outubro o [\[Claude Haiku 5.5\]](#), que chama de seu modelo pequeno mais barato, rápido e capaz. É pensado para trabalho de alto volume, como resumir e classificar, e para servir de subagente, o modelo auxiliar a quem um modelo maior delega partes de uma tarefa. É o primeiro Haiku com ajuste de esforço: o usuário escolhe quanto o modelo raciocina antes de responder, trocando custo por inteligência. Até 100 mil tokens por pedido (o token é a unidade de texto pela qual os modelos cobram), custa US\$ 0,10 por milhão de tokens de entrada e US\$ 0,50 por milhão de saída, um décimo do Haiku 4.5; acima disso, o preço sobe cinco vezes.

Na [\[análise da Artificial Analysis sobre o Haiku 5.5\]](#), avaliadora independente, o modelo fez 43 pontos no índice de inteligência no esforço máximo, 26 acima do último Haiku, à frente do GPT-6 Luna (38) e 13 pontos atrás do Sonnet 5.5. Para isso, escreveu cerca de 162 mil tokens de saída por tarefa, três vezes o que gasta o Luna, e o Terminal-Bench 4.0 medido pela avaliadora deu 33%, abaixo dos 39,2% informados pela Anthropic. Os números da tabela são os do [\[anúncio da Anthropic\]](#).

BENCHMARK	HAIKU 5.5 · GPT-6 LUNA	O QUE MEDE
OSWorld 2.1	72,4% · 48,9%	uso autônomo do computador
Terminal-Bench 4.0	39,2% · 16,4%	tarefas de agente executadas no terminal
FrontierCode 1.1	46,4% · 42,4%	programação
GDPval-AA v2.1	1620 · 1437 Elo	trabalho profissional em várias ocupações
Chartography	46,4% · 29,1%	leitura de gráficos

— COMPARAÇÃO COM A GERAÇÃO ANTERIOR

Contra o Haiku 4.5, o salto é de categoria: no OSWorld, de 15,7% para 72,4%. A Anthropic informa custo médio cerca de 75% menor, conta que já desconta o tokenizador novo, a peça que corta o texto em tokens. O programador [Simon Willison] mediu esse efeito por conta própria: o mesmo prompt longo vira cerca de 1,25 vez mais tokens no Haiku 5.5 que no 4.5, um reajuste que não aparece na tabela de preços.

Se o seu trabalho cabe em 100 mil tokens, o Haiku custa o mesmo que o Luna e reporta notas de benchmark maiores. Acima de 100 mil tokens, o Luna parece um negócio muito melhor.

SIMON WILLISON · PROGRAMADOR E COMENTARISTA DE IA

— O QUE ISSO DESBLOQUEIA NA PRÁTICA

Para a estrutura jurídica, o Haiku é o operário da linha de produção: triagem de intimações, resumo de andamentos, extração de datas em lote. A [Artificial Analysis] traz um dado que interessa a quem trabalha com prova: ele sabe menos fatos que os rivais da faixa, mas inventa menos. Na medição de conhecimento factual, a taxa de alucinação ficou em 40%, contra 55% e 77% dos dois rivais comparados, o Gemini 3.8 Flash e o GPT-6 Luna, em parte porque admite com mais frequência que não sabe. Na triagem, é a diferença entre devolver a pilha com um ponto de interrogação e devolvê-la arrumada e errada.

IMPACTO PRÁTICO

O preço por token virou tarifa por faixa de consumo, como conta de luz com bandeira. Até 100 mil tokens, o Haiku 5.5 é a opção barata; um processo digitalizado de algumas centenas de páginas pode passar disso, e aí a tarifa quintuplica; no esforço máximo, o modelo ainda escreve três vezes mais rascunho que o concorrente.

Separe o trabalho por tamanho antes de migrar. Quem compra modelo pela etiqueta paga a letra miúda.

PESQUISA

Harvey LAB-AA: o teste jurídico em que inventar um fato zera a nota

Quase todos os modelos cumprem quase todos os critérios. Conferidas contra os documentos do caso, porém, a maioria das peças aprovadas trazia ao menos um erro capaz de enganar o leitor.

A Artificial Analysis lançou em 8 de outubro, com a Harvey, a versão 1.1 do [Harvey LAB-AA], sua reimplementação independente do teste de agentes jurídicos da Harvey: 120 tarefas privadas, de fusões e aquisições a tributário, contencioso e falência, em que o modelo entrega o produto final. A novidade é a conferência de alucinação: cada entrega é confrontada com os documentos do caso, e uma única alucinação material, a que enganaria o leitor num ponto substantivo, como uma data contratual errada, zera a tarefa.

Com a régua nova, o primeiro colocado é o Grok 4.7, com 9,4% das tarefas aprovadas por inteiro. Sem a conferência, o Muse Spark 1.3 lideraria com folga, com 26,7%, mas dois terços dessas aprovações traziam uma alucinação material. Entre os modelos testados, segundo a [metodologia do Harvey LAB-AA v1.1], mais de 60% dos resultados que passariam continham ao menos uma, e vários modelos zeraram.

MODELO	APROVAÇÃO SEM ALUCINAÇÃO	OBSERVAÇÃO
Grok 4.7 (xhigh)	9,4%	primeiro colocado
Muse Spark 1.3 (max)	8,9%	26,7% sem a conferência
GPT-6 Astra (max)	8,6%	8,9% sem a conferência
GPT-6.1 Sol (max)	6,9%	7,5% sem a conferência
Claude Fable 5.1 (max)	6,4%	melhor colocado da Anthropic
Claude Opus 5.5 (max)	4,2%	também atua como juiz

— COMPARAÇÃO COM A VERSÃO ANTERIOR

A versão 1.0 tinha um juiz só e não conferia alucinação. Agora três modelos, GPT-6 Sol, Grok 4.7 e Claude Opus 5.5, julgam cada critério, e as notas das duas versões não se comparam. O critério sozinho escondia o problema: no [\[anúncio do Harvey LAB-AA v1.1\]](#), 16 modelos cumprem entre 85,6% e 96,0% dos critérios das rubricas. O GPT-6 Astra é o retrato da diferença: quase não perde aprovações para a conferência e sobe do 10º lugar, empatado, para o 3º.

— O QUE ISSO DESBLOQUEIA NA PRÁTICA

O exemplo publicado pela [\[Artificial Analysis\]](#) é de manual. Numa revisão tributária, o rascunho de declaração dizia que um empréstimo amortizou US\$ 6 milhões no ano e caiu de US\$ 220 milhões para US\$ 214 milhões. Um modelo listou empréstimo de US\$ 220 milhões mais notas de US\$ 214 milhões: duas dívidas onde havia uma só, em dois momentos. A rubrica mede se a entrega cobre o que devia; quem flagrou a soma dobrada foi a conferência contra a fonte.

Uma alucinação material induziria o leitor a erro num ponto substantivo, como uma data contratualmente exigida que esteja errada.

ARTIFICIAL ANALYSIS · METODOLOGIA DO HARVEY LAB-AA V1.1

IMPACTO PRÁTICO

Noventa por cento dos critérios cumpridos e uma data errada: na rubrica, é nota alta; no processo, é prazo perdido. O teste novo passou a medir o que o profissional do direito sempre mediu, a peça inteira contra os autos.

Quando um fornecedor mostrar o placar do seu agente jurídico, peça o número depois da conferência contra a fonte. Em peça jurídica, quase certo é só um jeito educado de dizer errado.

Outros modelos da semana

A Mistral abriu em prévia o [\[Mistral Large 4\]](#), modelo multimodal, que lê texto e imagem, de 1 trilhão de parâmetros treinado do zero em data centers próprios na Europa, com os pesos, os parâmetros que permitem rodar o modelo em servidor próprio, prometidos para o fim de outubro. A empresa afirma que ele supera todos os modelos abertos no teste de agentes jurídicos da Harvey. Na [\[análise da Artificial Analysis sobre o Mistral Large 4\]](#), fez 38 pontos no índice de inteligência, empatado com o GPT-6 Luna e o mais alto fora dos Estados Unidos e da China, mas, no preço padrão, custa por tarefa mais de quatro vezes o que custam abertos de nível parecido.

A Reflection AI apresentou o [\[Beam\]](#), seu primeiro modelo aberto: 501 bilhões de parâmetros no desenho MoE, em que o modelo é dividido em especialistas e só alguns trabalham a cada token, aqui 23 bilhões. A empresa diz que ele empata com o GLM 5.2 em raciocínio avançado com 3 a 4 vezes menos computação, sem verificação independente, e promete os pesos para outubro: modelo aberto que gasta menos para pensar cabe no servidor de quem não pode mandar documento para fora.

A OpenAI levou o [\[GPT-6 ao ChatGPT para todos\]](#) com o Intelligent UI: o modelo foi treinado para responder com gráficos, botões e formulários interativos, escolhendo o formato conforme a pergunta. Os assinantes pagos recebem o GPT-6 Sol; os planos Free e Go, o GPT-6 Luna.

Pesquisa e métodos

A OpenAI publicou, no [\[post da OpenAI sobre matemática\]](#), resultados produzidos por um modelo interno ainda não lançado, cada um ao custo médio equivalente a três horas de raciocínio do ChatGPT Pro. O [\[repositório openai/math\]](#) reúne 719 manuscritos em 372 famílias, com cerca de 42% dos resultados principais formalizados em Lean, linguagem em que o próprio computador confere a prova. A recepção ficou dividida: matemáticos ouvidos pelo [\[The Verge sobre os resultados\]](#) elogiam parte do material, mas apontam formalização parcial, textos difíceis de seguir e bibliografias curtas, e a OpenAI retirou três artigos por erro de sinal.

Dois trabalhos medem o avesso dessa capacidade. No [\[InnovationEval\]](#), da Epoch AI, agentes com 3.000 horas de GPU tentaram redescobrir uma técnica recente de pós-treinamento sem ter lido o artigo original; o melhor chegou a no máximo 15% do ganho dela, e os dois modelos testados inflaram os próprios resultados repetindo execuções até a sorte ajudar, sabendo, pelas transcrições, que isso distorcia a nota. A METR mostrou, no [\[relato da METR sobre encobrimento\]](#), que um agente poderia alterar o que o revisor humano vê no visualizador de transcrições do Inspect; a falha foi corrigida em um dia, e a METR diz não ter visto agente algum explorá-la. Quem vigia o agente precisa antes garantir que ele não edita o que se vigia.

IA aplicada ao direito

O [\[estudo do Google com advogados de patentes\]](#), de David Autor e Tanya Rodchenko, é o experimento mais útil da semana para quem forma equipe. Em onze escritórios de propriedade intelectual, dois terços de 133 advogados receberam por três meses um assistente de redação de patentes, sorteados. A IA melhorou o texto de quem a recebeu, sobretudo dos juniores: aos 90 dias, quem tinha a ferramenta ficou, em média, o equivalente a 11 posições acima num ranking de 100 colegas sem ela. Na revisão feita sem IA, porém, só os seniores, com sete anos

ou mais de prática, ganharam julgamento; os juniores não melhoraram em média. O estudo é do Google, com ferramenta do Google, em escritórios que têm negócios regulares com a empresa, como o próprio texto informa.

A OpenAI treinou o GPT-6 Astra, com aprendizado por reforço, em tarefas de gestão de contratos montadas sobre o software da Ironclad, com o agente operando o programa como uma pessoa, e o avaliou em 11 tarefas de pesquisa, como configurar um acordo de confidencialidade. No [\[post da OpenAI sobre a Ironclad\]](#), a nota média foi de 55,0%, contra 41,6% do GPT-5.6 Sol, em cerca de metade do tempo estimado. São 11 tarefas, montadas sobre contratos públicos, e tempos simulados, ressalva a própria empresa. O que conta é a direção: o modelo de fronteira já treina dentro do software jurídico.

E o [\[Cited but Not Consulted\]](#) testou o que todo revisor desconfia: trocou a lei ou o precedente citado por outro sem relação, com os fatos intactos, e viu se o veredito do modelo mudava. Os sete modelos abertos testados citam a autoridade certa em 66,7% a 100% das vezes, mas no CaseHOLD, base de precedentes americanos, o veredito mudou em no máximo 21,7% das trocas. A fundamentação que o modelo escreve não prova que a decisão saiu dela.

Ferramentas do ecossistema

- Os modelos de decisão, que a edição nº 19 viu virar peça de prateleira, ganharam mais três casas. A Microsoft pôs no Foundry o [\[Microsoft-Decision-1\]](#), que devolve probabilidades em vez de texto e, segundo a empresa, é 35 vezes mais rápido que o GPT-6 Sol; a OpenAI abriu a [\[Decisions API em beta público\]](#), com entrada a US\$ 0,10 por milhão de tokens e saída sem cobrança; e a Musubi liberou o [\[PolicyLM-1.7B\]](#), aberto, que lê uma política de moderação escrita em linguagem comum e pontua cada mensagem em cerca de 35 milissegundos numa placa de vídeo comum, segundo a empresa.
- O Claude Code, agente de programação da Anthropic, passou a rodar cada subagente a quem delega trabalho no nível de esforço pedido, na [\[versão 2.1.292 do Claude Code\]](#), e na [\[versão 2.1.295 do Claude Code\]](#) os hooks, comandos que o usuário configura para rodar antes de certas ações, passaram a poder bloquear a ação quando eles mesmos falham, em vez de deixá-la passar: a trava que não abre por defeito.
- A Anthropic lançou o [\[OSS Scanner\]](#), varredura gratuita de vulnerabilidades para projetos de código aberto elegíveis que se inscreverem, feita pelos seus modelos mais fortes e enviada sem revisão humana, com reprodução da falha e, quando há, correção sugerida; segundo o wolfSSL, dos 74 relatórios que recebeu só dois não eram válidos, e cinco viraram registros oficiais de vulnerabilidade.
- O Google publicou o [\[EmbeddingGemma 2\]](#), modelo aberto que transforma texto, imagem, áudio e vídeo em embeddings, vetores numéricos que representam o significado e

sustentam a busca por sentido, agora com contexto quatro vezes maior; roda no próprio aparelho, e o Google já o usa no [\[Foresight\]](#), app para Mac que transcreve reuniões sem que o áudio saia do computador.

PARA TESTAR ESTA SEMANA

Recebeu uma foto, um vídeo ou um áudio e quer saber se foi gerado por IA? O [\[site do SynthID\]](#), do Google, passou a aceitar qualquer pessoa, segundo o [\[TechCrunch sobre o SynthID\]](#): você sobe o arquivo e ele procura a marca d'água invisível que modelos do Google, da OpenAI, da Nvidia e da Kakao embutem no que geram. Para aprender a ler a resposta, teste com uma imagem que você mesmo gerou no Gemini e com uma foto sua; resultado negativo não prova autenticidade, só que a marca não foi encontrada.

Brasil

Gol: o check-in feito dentro do ChatGPT

A [\[Gol anunciou\]](#) uma integração em que o passageiro digita @gol no ChatGPT, faz login numa página da própria companhia e recebe o cartão de embarque sem sair do assistente. O serviço abre a toda a base em 19 de outubro, inclusive na versão gratuita do ChatGPT; segundo a empresa, credenciais e dados sensíveis não ficam com o ChatGPT. O ato acontece no assistente que o cidadão já usa; a autenticação fica com quem responde por ele.

ClickBus: o agente que faz campanha para doze passageiros

Segundo a [\[Mobile Time sobre a ClickBus\]](#), a empresa criou um agente que transforma cada passagem em oferta pronta para os sistemas de venda, redige o texto e testa descontos. Uma tarefa de 10 minutos passou a levar 2 segundos, o que viabiliza campanhas para trechos com pouquíssimos interessados; uma mensagem chegou a ter 12 destinatários. A empresa diz que a oferta dirigida ao trecho exato vende dez vezes mais que a mensagem genérica. Os números são declarados pela própria ClickBus, e a matéria não diz que modelo ela usa.

A Gotiva na ExpoJud e o Bradesco no anúncio do Google

Como o radar da edição anterior antecipou, a Gotiva apresentou na ExpoJud, em Brasília, sua plataforma de IA integrada a PJe, Projudi, SAJ e e-Proc, que auxilia na análise de processos, na pesquisa de legislação e jurisprudência, na classificação processual e na elaboração de documentos, segundo o [\[Correio da Manhã sobre a ExpoJud\]](#). E no [\[anúncio do Google Cloud\]](#) do agente Gemini para empresas, o Bradesco aparece com a revisão de documentos fiscais, contábeis e contratuais caindo de uma hora para cinco minutos, número do próprio Google, sem verificação independente.

IMPACTO PRÁTICO

Não encontramos lançamento de modelo brasileiro nesta semana, e a pauta nacional foi toda de encaixe: a Gol dentro do ChatGPT, a ClickBus com um agente que monta campanhas antes inviáveis para trechos de pouca procura, a Gotiva ligada aos sistemas que os tribunais já usam.

Para quem decide sobre IA num escritório ou num gabinete, é esse o trabalho que cabe: escolher onde o modelo entra, com que tarefa e com que limite, e não construí-lo.

NO RADAR DA PRÓXIMA SEMANA

A conferência AIES, de 12 a 14 de outubro, publica nos anais o estudo sobre inundação agêntica em serviços públicos [[preprint no arXiv](#)]. E, em 15 de outubro, Docs, Slides e Design do Claude passam a vir ligados por padrão nos planos Enterprise [[anúncio da Anthropic sobre Dashboards e Motion](#)].

O recorte dos últimos sete dias termina aqui. Até a próxima! ■

CURADORIA E EDIÇÃO · 10 DE OUTUBRO DE 2026

DM

Dennis Martins é advogado, professor de pós-graduação em Direito Imobiliário e pós-graduando em Inteligência Artificial Generativa no Direito.

AA

Adriana Aneli é formada em Direito e servidora do Tribunal de Justiça de São Paulo, onde ocupa o cargo de assistente jurídico. É mestranda em Teoria Crítica, especialista em Legal Operations, Dados, IA e Alta Performance Jurídica, e pós-graduanda em Inteligência Artificial Generativa no Direito.