RADAR SEMANAL · PARA ESCRITÓRIOS, GABINETES E ASSESSORIAS

IA em Cognição Nada Exauriente

EDIÇÃO Nº 23 INVENTÁRIO DOS PRINCIPAIS FATOS OCORRIDOS DE 24 DE OUTUBRO A 31 DE OUTUBRO DE 2026

Resumo

Em sete dias, três casas de fronteira puseram na rua os modelos mais capazes que já tinham, e uma quarta, europeia, abriu os pesos do seu. O Google lançou o Gemini 4 Carbon, que o principal avaliador independente pôs em primeiro lugar e que, num detalhe que importa a esta carta, também lidera o teste de pesquisa jurídica da Vals. A Mistral liberou os pesos do Mistral Large 4, cumprindo o prazo que o radar da semana passada cobrava, e com isso devolveu ao Ocidente o melhor modelo aberto para programação. E a OpenAI anunciou três resultados científicos atribuídos aos seus modelos, entre eles a refutação de uma conjectura que sustenta centenas de artigos de teoria da computação. No mesmo intervalo, o índice que coroou o Carbon foi reescrito, e a distância entre o melhor modelo aberto e o melhor fechado, que era de três pontos, voltou a doze.

No entorno, a OpenAI lançou o GPT-6.1 Terra, modelo de expediente que custa metade do anterior e chuta bem menos quando não sabe a resposta, e a Epoch mostrou um modelo aberto transformando sozinho correções de segurança do Firefox em ataques funcionais, pela fresta entre o conserto publicado e o conserto instalado. A semana jurídica foi de enxurrada de ferramentas: a Anthropic abriu uma galeria de peças prontas no Claude for Legal, a Clio refez a plataforma inteira em torno de agentes e a Everlaw apresentou a sua suíte agêntica. No Brasil, uma pesquisa da FGV Direito SP mediu como a advocacia nacional já usa IA generativa, e o retrato tem mais sombra que luz.

MODELO PROPRIETÁRIO

Gemini 4 Carbon: o Google assume a ponta e, de quebra, o teste jurídico

A liderança no índice geral é a manchete. O dado que interessa a quem advoga está numa coluna lateral: o primeiro lugar na pesquisa jurídica medida por terceiros.

Duas semanas depois do Gemini 4 Argon, o Google anunciou o [Gemini 4 Carbon], que chama de seu modelo mais forte. A estreia veio com o acesso fechado: o modelo começa liberado a um subconjunto de defensores de segurança cibernética e se abre aos poucos a parceiros de confiança pelo programa Fairwind, sem data para desenvolvedores e empresas. Segundo a

[Artificial Analysis], avaliadora independente, lê texto, imagem, vídeo e fala, responde em texto e tem janela de 1 milhão de tokens, a medida de quanto texto cabe de uma vez na memória de trabalho do modelo.

Na [versão 5] do índice de inteligência da avaliadora, publicada em 27 de outubro, o Claude Opus 5.5 liderava com 58 pontos. No dia seguinte, a [análise do Carbon] deu 59 ao modelo do Google, que assumiu o primeiro lugar. Lidera quatro das nove provas, entre elas as de conhecimento e as de ciência. No índice de agente de programação, área em que o Google historicamente ficava para trás, encostou no líder: 59 contra 62 do Opus 5.5. O destaque que o próprio Google ergue, porém, é a segurança cibernética.

AVALIAÇÃO	GEMINI 4 CARBON	O QUE MEDE
Intelligence Index v5	**59**	média das provas da Artificial Analysis (1º lugar; Opus 5.5: 58)
Coding Agent Index	**59**	tarefas de agente de código (Opus 5.5: 62)
Terminal-Bench 4.0	**64%**	agente no terminal (2º lugar, atrás do Opus 5.5)
AA-Omniscience v1.1	**54**	conhecimento e baixa taxa de invenção (acurácia 58%)

COMPARAÇÃO COM A GERAÇÃO ANTERIOR

Sobre o Argon, de duas semanas antes, o Carbon soma nove pontos no índice. Comparado ao Claude Opus 5.5, que ficou logo atrás, gasta 29% menos tokens por tarefa e sai cerca de 23% mais barato. Na conferência de honestidade, o salto é desigual: a acurácia subiu dez pontos, para 58%, mas a taxa de invenção, de 4% no Argon, subiu para 11%, segundo a Artificial Analysis. Ainda é a segunda menor entre os grandes, atrás só do Argon, contra 50% do Opus 5.5 e do GPT-6 Astra. Já o [blog do Google] afirma que o Carbon reduziu em 26% os casos em que faz mais do que foi pedido e em 29% os casos em que faz menos.

O QUE ISSO DESBLOQUEIA NA PRÁTICA

Na [avaliação jurídica da Vals], o Carbon ficou em primeiro de 89 modelos na prova de pesquisa jurídica, com 55,77%, à frente do Argon da quinzena anterior. Um primeiro lugar conduzido por terceiro vale mais que o número que o fabricante escolhe publicar, porque a Vals não vende o modelo. Mas leia o que o teste é antes de confiar nele: 55,77% de acerto significa que o melhor modelo do mundo erra quase metade das questões da prova. O número serve para comparar modelos entre si, não para dispensar a conferência. É a diferença entre a melhor testemunha disponível e a prova dos autos: a testemunha orienta, o documento decide. Some-se a isso que o Carbon ainda não está aberto ao público, o que, por ora, mantém a liderança no terreno da promessa.

IMPACTO PRÁTICO

O topo do ranking geral é provisório: o Opus 5.5 ficou nele cerca de um mês, e a régua que o mede acabou de ser reescrita. Para quem contrata, isso é ruído. O sinal está na prova específica: o modelo que lidera a pesquisa jurídica medida por fora é um dado utilizável, desde que se leia a nota de rodapé de que ele acerta pouco mais da metade.

Escolher assistente de IA pela manchete do índice é como escolher perito pela fama. O que decide a causa é o laudo conferido contra os autos, não o nome na capa.

MODELO OPEN-SOURCE

Mistral Large 4: a Europa reabre os pesos do melhor modelo aberto para código

Abrir os pesos resolve para onde o documento vai. A medição da própria casa mostra que a liderança é clara em programação e discutível em segurança, a bandeira que a empresa ergueu.

Prometido para o fim de outubro no radar da edição passada, o prazo venceu em dia: a Mistral [liberou os pesos do Mistral Large 4], apelidado Le Chonk, modelo multimodal, capaz de ler mais que texto, de cerca de 1 trilhão de parâmetros treinado do zero na Europa. Pesos abertos são os arquivos internos do modelo, que permitem rodá-lo em servidor próprio, sem mandar documento algum para a nuvem de terceiros. A licença é uma MIT modificada: livre para usar, adaptar e explorar comercialmente, com uma exceção, quem revende o modelo como serviço precisa de licença à parte.

É um MoE, sigla de mistura de especialistas, arquitetura em que só uma fração dos "especialistas" internos acorda a cada palavra gerada. Segundo as notas de versão do [Transformers da Hugging Face], que já o suporta na mesma semana do lançamento, o modelo lê texto e imagem e, dos seus 128 especialistas, aciona 4 por token, mais 1 fixo, de modo que o custo de operação é muito menor que o trilhão de parâmetros sugere. Tem janela de 1 milhão de tokens e três níveis de esforço de raciocínio, o botão que troca velocidade por profundidade da resposta. Os números abaixo são do [anúncio da Mistral].

AVALIAÇÃO	MISTRAL LARGE 4	O QUE MEDE
Coding Agent Index	**48%**	agente de código (empata GLM-5.3, com 47% menos tokens)
Terminal-Bench 4.0	**41%**	agente no terminal (era 28% na prévia)
FrontierCode 2.0	**19,7%**	código que um mantenedor aceitaria (lidera os abertos)
Cyber Index	**51%**	achar e corrigir vulnerabilidade (DeepSeek V4.1 Flash: 57%)
Recusa a pedido malicioso	**96,6%**	bloqueio de uso ofensivo de cibersegurança

COMPARAÇÃO COM A GERAÇÃO ANTERIOR

Sobre a prévia de três semanas antes, o ganho veio de mais aprendizado por reforço, a etapa de treino em que o modelo é recompensado por acertar tarefas: o Terminal-Bench 4.0 subiu de 28% para 41% e assumiu a ponta entre os abertos, gastando 30% menos tokens. A Mistral, porém, se apresenta como o melhor aberto para código e segurança cibernética, e aqui convém ler o gráfico da própria empresa: no índice de cibersegurança ela marca 51%, mas o mesmo gráfico mostra o DeepSeek V4.1 Flash com 57% e o MiMo-V2.6-Pro com 56% acima dela. A liderança clara é em programação. Em segurança, o número é bom, não o primeiro.

O QUE ISSO DESBLOQUEIA NA PRÁTICA

Pesos abertos querem dizer que o escritório, o gabinete ou o departamento jurídico pode rodar o modelo na própria máquina, sem que a minuta, o contrato ou o documento do cliente saiam para o servidor de ninguém. É o argumento que Pierre Stock, vice-presidente de ciência da Mistral, resume em imagem doméstica à [reportagem do Wired], e que para a advocacia se traduz em sigilo profissional preservado por desenho, não por cláusula de contrato. O preço de API, para quem não quiser hospedar, é de 70 centavos de dólar por milhão de tokens de entrada.

> *A IA vai ser como a eletricidade. Você não quer viver num mundo em que o seu vizinho pode cortar a sua energia de um dia para o outro.*
>
> PIERRE STOCK · VP DE CIÊNCIA, MISTRAL, AO WIRED

> **IMPACTO PRÁTICO**
>
> O que a empresa oferece de concreto é controle: o modelo roda onde o dono mandar, e o

documento não precisa viajar. O que ela oferece de retórica é a liderança em cibersegurança, e essa a própria tabela da casa desmente. As duas coisas vieram no mesmo anúncio, e só a primeira é verificável abrindo os pesos.

Para quem guarda segredo alheio, a pergunta não é qual modelo pontua mais. É qual deles você pode manter dentro de casa. Esse, agora, tem pesos abertos e nome de gato gordo.

PESQUISA

OpenAI diz ter derrubado uma hipótese que sustenta centenas de artigos

O resultado matemático, se confirmado, é grande. A novidade que muda o jogo, porém, está em quem a empresa chamou desta vez para dizer se a prova vale.

ACOMPANHAMENTO *Edições nº 11 a 20: os dez problemas de matemática resolvidos por um modelo interno da OpenAI, entre eles três de Erdős; a prova de que as equações de Navier-Stokes podem explodir em tempo finito; e os 719 manuscritos despejados de uma vez, que matemáticos acharam difíceis de conferir. Agora a empresa mudou o processo.*

O que mudou nesta semana não foi a ambição, foi o método de divulgação. Em vez de abrir mais um repositório e deixar a comunidade se virar, a OpenAI chamou especialistas externos para "pastorear" cada resultado, organizando grupos que vão conferir e explicar o que o modelo produziu, segundo o [anúncio da OpenAI]. São três resultados: uma prova de uma conjectura de análise harmônica em todas as dimensões, a existência matemática rigorosa da cromodinâmica quântica, que descreve a força forte entre quarks, e a refutação da Hipótese do Tempo Exponencial.

Essa última é a que toca mais gente. A Hipótese do Tempo Exponencial, ou ETH, trata de decidir se uma fórmula lógica pode ser satisfeita, isto é, se há valores de verdadeiro e falso que a tornem verdadeira. Afirma que não há atalho de fundo: existem métodos melhores que testar todas as combinações, mas, no pior caso, o tempo de qualquer um cresce exponencialmente com o número de variáveis. Centenas de artigos de teoria da computação a tomam como verdadeira para derivar seus próprios resultados. A OpenAI diz que seu sistema a refutou, e que a refutação foi verificada em Lean, linguagem em que o próprio computador confere cada passo da prova. O grupo que vai examinar o caso é liderado por Impagliazzo e Paturi, da Universidade da Califórnia em San Diego, que formularam a ETH, e por Ryan Williams, do MIT. Ainda é alegação da empresa, sem a confirmação independente que o próprio grupo foi montado para dar.

> *“No conjunto, o mundo merece entender como o universo funciona.”*
>
> SAM ALTMAN · CEO DA OPENAI, AO PODCAST CHEEKY PINT

COMPARAÇÃO COM OS ANÚNCIOS ANTERIORES

Até aqui, a crítica recorrente era a verificação: os 719 manuscritos de matemática que a OpenAI publicou de uma vez em outubro, registrados na edição nº 20, saíram com formalização parcial e textos que matemáticos acharam difíceis de seguir. A mudança de agora responde a isso ao convidar os revisores antes de publicar, embora de forma desigual: o resultado de matemática saiu sem grupo prévio, o de ciência da computação com grupo e publicação imediata, e o de física ficou retido pelos próprios revisores. A pressa segue sendo a marca da casa: em entrevista ao podcast Cheeky Pint, reproduzida pelo [The Verge], Sam Altman disse ter empatia pelos matemáticos que não acompanham o fluxo, mas que não vai parar de divulgar, e confirmou haver mais resultados guardados.

O QUE ISSO DESBLOQUEIA NA PRÁTICA

Para o profissional do direito, o que importa aqui não é a matemática, é o desenho do processo. A OpenAI separou quem produz o resultado de quem responde por ele: o modelo prova, um grupo externo e independente confere, e só então o resultado entra no mundo. É a arquitetura que a própria advocacia conhece pela perícia e pela segunda opinião. A pergunta que fica, e que vale para qualquer trabalho feito por máquina, é quem assume a autoria e quem assume a responsabilidade quando as duas deixam de ser a mesma pessoa.

> **IMPACTO PRÁTICO**
>
> A notícia não é que a máquina provou um teorema. É que a empresa, depois de meses levando bronca por publicar sem deixar conferir, passou a convocar conferentes externos para examinar o resultado antes que ele vire ciência estabelecida. A verificação deixou de ser um problema do leitor para virar parte do processo.
>
> Quando a autoria é da máquina e a responsabilidade é de quem a opera, a conferência independente para de ser elegância acadêmica. Vira a única coisa que separa a descoberta do boato bem formatado.

Outros modelos da semana

A OpenAI lançou o [GPT-6.1 Terra], modelo de expediente voltado a tarefas como redigir, preencher formulário e operar telas. O que muda é a economia e a honestidade: custa 1 dólar por milhão de tokens de entrada e 5 de saída, metade do anterior, e, segundo a [Artificial Analysis], chuta 38% das vezes em que não sabe a resposta, contra 88% do GPT-5.6 Terra, uma queda de 50 pontos na taxa de invenção. Para triagem em volume, inventar menos pela metade do preço importa mais que subir no ranking.

A NVIDIA publicou o [Nemotron 3.5], família aberta de arquitetura híbrida que mistura camadas Transformer com um tipo mais barato de memória, mirando agentes e contexto longo: o modelo de 120 bilhões de parâmetros supera a geração anterior no SWE-bench Pro com cerca de 4,6 vezes menos parâmetros ativos. E o Kimi K3.1 Pro, que estreou na semana retrasada em quarto no índice independente, segue com os pesos prometidos para 4 de novembro, prazo que ainda não venceu.

Pesquisa e métodos

O tema da semana passada voltou pelo avesso. A [Epoch AI] mostrou que o GLM 5.3, modelo de pesos abertos da Z.ai, transformou sozinho correções de segurança já publicadas pela Mozilla, mas ainda não instaladas pelos usuários, em ataques funcionais contra o Firefox. Comprometeu as seis versões lançadas entre 17 de setembro e 26 de outubro, a cerca de mil dólares de computação cada, explorando a fresta entre o conserto publicado e o conserto que chega à máquina, o chamado “patch gap”. O mesmo ataque ao Chrome falhou, mesmo com cem mil dólares gastos. A lição para quem administra sistema é a mais prosaica possível: atualizar virou corrida contra o relógio.

Em métodos, três trabalhos. O [sleep framework, do Google Research] propõe que o modelo alterne entre uma fase ativa e uma fase de “sono”, em que consolida nos próprios pesos o que aprendeu, para contornar a data de corte de conhecimento sem esquecer o que já sabia. Um estudo da [Together] mediu a economia do botão de esforço de raciocínio e achou que o nível máximo chega a custar 42 vezes o mínimo nas tarefas fáceis, sem melhorar o resultado. E um paper de Yann LeCun sobre [representações aprendidas] prova que modelos de modalidades diferentes convergem para a mesma representação do mundo quando aprendem prevendo representações, e que a escolha de bons exemplos pesa mais que o tamanho.

IA aplicada ao direito

A semana foi de plataforma, não de modelo. A Anthropic abriu uma galeria de peças prontas no [Claude for Legal], ferramentas interativas que o time jurídico adapta com os próprios documentos: uma confere se as citações de uma peça batem com a fonte, outra monta tabela comparando contratos com os termos-padrão da empresa e sinaliza cada cláusula divergente. Cada resposta traz o link para o trecho exato. O comentário independente da Artificial Lawyer é sóbrio: não é salto técnico, é o Claude mais um conjunto de roteiros jurídicos, e um bom engenheiro jurídico faria parecido.

Na [abertura do ClioCon], a Clio fundiu captação, gestão e trabalho jurídico numa interface única, a entrar no ar em novembro, e apresentou os Agentic Workflows: a banca descreve um procedimento em linguagem comum e o sistema monta as etapas, com pontos de parada para aprovação do advogado antes de agir. E a [Everlaw], plataforma de análise de documentos para litígio, lançou a suíte agêntica Omni e, segundo o CEO, o que mais entusiasma os clientes não é a IA própria, mas a abertura da plataforma às ferramentas que eles já usam, por conectores padronizados. O eixo comum das três é o mesmo: a disputa saiu do modelo e foi para o que está ligado a ele.

Ferramentas do ecossistema

- O [Claude Code 2.1.314] ganhou uma trava que recusa escrita fora das pastas de trabalho em qualquer modo de permissão, controle útil para quem deixa o agente operar com autonomia sobre uma máquina com dados sensíveis.
- O [Ollama 0.40.12], programa que roda modelos no próprio computador, somou a família LFM3 da Liquid AI, modelos pequenos para agentes locais, com chamada de ferramentas e saída estruturada, úteis para triagem sem enviar dado à nuvem.
- A biblioteca [diffusers 0.42.1], de geração de imagem, saiu numa versão de segurança que corrige um desvio da trava contra execução de código vindo de repositórios de terceiros; quem baixa modelos de imagem de fora deve atualizar.
- A OpenAI reorganizou o [Model Spec], o documento público que descreve como a empresa quer que seus modelos se comportem, em torno de cinco valores, e admite que os modelos “ainda não o refletem plenamente”: leitura de interesse para quem monta fluxo sobre a API e precisa saber o que o usuário pode sobrescrever e o que é limite firme.

PARA TESTAR ESTA SEMANA

O modo de “raciocínio máximo” do seu assistente vale o tempo e o custo que cobra? Pegue uma tarefa sua de rotina, como resumir uma minuta fictícia, e peça a mesma coisa em esforço baixo e em esforço máximo. Um [estudo da Together] mediu que o nível máximo pode custar até 42 vezes o mínimo e, em tarefas simples, não melhora a resposta. Se as duas saídas forem equivalentes, baixe o esforço e economize; se a máxima for claramente melhor, você achou onde ela vale a pena. O teste leva dois pedidos.

Análise

Na mesma semana em que coroou o Carbon, a Artificial Analysis reescreveu o próprio índice. A [versão 5] passa a montar 60% da nota sobre testes privados, que os laboratórios não podem treinar de cor, e com isso a distância entre o melhor modelo aberto e o melhor fechado, que no índice anterior era de três pontos, voltou a doze. O melhor aberto com pesos de fato liberados faz 32 e perde para o pequeno Claude Haiku 5.5. Há uma ironia no calendário: o fosso reabre na mesma semana em que a Mistral devolve ao Ocidente um aberto de ponta. No [Interconnects], Nathan Lambert observa que todo criador de benchmark carrega sua visão de mundo, e que o índice anterior favorecia demais os modelos abertos. A lição é que a distância que o leitor vê depende de quem escreve a régua.

Brasil

FGV Direito SP: a advocacia usa muito e confere pouco

O Centro de Ensino e Pesquisa em Inovação da FGV Direito SP divulgou, segundo o [Conjur], um estudo sobre o uso de IA generativa no direito brasileiro, com 495 respostas válidas colhidas entre fevereiro e março de 2026. O retrato é de adoção alta e cautela baixa: cerca de 80% usam a ferramenta com frequência, 58% diariamente, mas mais de 80% a empregam em temas que não dominam plenamente e, em 43,5% dos casos, só o próprio profissional confere o resultado, sem revisão de segundo. Metade das organizações não tem política interna de uso. Marina Feferbaum, coordenadora do CEPI, chama o fenômeno de “shadow AI”, o uso que acontece à margem de qualquer controle.

Renov e Venda.ai: duas métricas de IA em operação

Dois casos de aplicação com número divulgado, ambos autodeclarados pelos fornecedores. A [Renov], de troca de celulares usados, pôs em produção a quarta geração do seu sistema que avalia o estado do aparelho a partir de quatro fotos e derrubou o tempo médio de avaliação de

15 para 3 minutos, embora não publique taxa de acerto. E a [Venda.ai] relatou que, em mais de 241,5 mil interações de agentes de IA no varejo entre julho e setembro, 88,5% foram resolvidas pela própria IA, sem atendente humano. Nenhum dos dois traz metodologia externa; valem como retrato de que o agente conversacional já trabalha em escala no comércio nacional.

IMPACTO PRÁTICO

A pesquisa da FGV mede no Brasil o que o teste da Vals mede lá fora: a máquina acerta a maior parte, não toda, e quem decide se a diferença importa é quem confere. Só que aqui o dado é sobre o conferente, não sobre o modelo, e ele diz que, em quase metade dos casos, ninguém além do próprio autor olha o resultado.

O risco não é a ferramenta que erra. É a banca que adotou a ferramenta antes de adotar a regra de conferir. Tecnologia nova com hábito velho de não revisar não soma, multiplica o que já estava torto.

NO RADAR DA PRÓXIMA SEMANA

A Moonshot prometeu os pesos completos do Kimi K3.1 Pro até 4 de novembro, prazo que vence nos próximos dias [blog da Moonshot]. Se saírem, será o modelo aberto mais alto no índice independente, três pontos à frente do que a versão 5 agora mede como melhor aberto.

O recorte dos últimos sete dias termina aqui. Até a próxima! ■

CURADORIA E EDIÇÃO · 31 DE OUTUBRO DE 2026

DM — **Dennis Martins** é advogado, professor de pós-graduação em Direito Imobiliário e pós-graduando em Inteligência Artificial Generativa no Direito.

AA — **Adriana Aneli** é formada em Direito e servidora do Tribunal de Justiça de São Paulo, onde ocupa o cargo de assistente jurídico. É mestranda em Teoria Crítica, especialista em Legal Operations, Dados, IA e Alta Performance Jurídica, e pós-graduada em Inteligência Artificial Generativa no Direito.